

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - Nguyễn Đức Mạnh -
Lê Quang Vĩnh Quyền

CẢI TIẾN
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, Ngày 11 tháng 1 năm 2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - 21120081

Nguyễn Đức Mạnh - 22120204

Lê Quang Vĩnh Quyền - 22120307

CẢI TIẾN
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lê Hoàng Thái

ThS. Dương Thái Bảo

Tp. Hồ Chí Minh, Ngày 11 tháng 1 năm 2026

Lời cam đoan

Chúng tôi xin cam đoan rằng đây là công trình nghiên cứu của chính chúng tôi. Dữ liệu và kết quả nghiên cứu trình bày trong báo cáo khóa luận là trung thực và không trùng lặp với bất kỳ đề tài nào khác. Chúng tôi cam kết rằng toàn bộ nội dung của báo cáo này không sao chép hay đạo văn từ bất kỳ công trình nghiên cứu nào khác.

Trong suốt quá trình thực hiện khóa luận, chúng tôi luôn chấp hành đầy đủ các quy định về đạo đức nghiên cứu, đảm bảo trích dẫn đúng và đầy đủ tất cả các nguồn tài liệu tham khảo, đồng thời giữ vững tinh thần trung thực học thuật trong mọi khía cạnh của báo cáo.

Lời cảm ơn

Có cần không ?

Trước hết, chúng tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc đến PGS.TS. Lê Hoàng Thái và ThS. Dương Thái Bảo vì sự hướng dẫn tận tình, khích lệ và hỗ trợ quý báu, giúp chúng tôi có cơ hội khám phá các hướng nghiên cứu mới.

Trong suốt quá trình thực hiện đề tài, quý Thầy đã chia sẻ những kiến thức giá trị và đóng góp nhiều gợi ý sâu sắc, giúp chúng tôi định hướng được con đường nghiên cứu của riêng nhóm thông qua các buổi trao đổi từ những ngày đầu cho đến khi hoàn thành nghiên cứu.

Mục lục

Lời cảm ơn	ii
Mục lục	iii
Danh sách hình vẽ	vi
Danh sách bảng	vii
Tóm tắt	vii
1 Giới thiệu	1
1.1 Bối cảnh chung	1
1.2 Động lực	2
1.3 Phát biểu bài toán	3
1.4 Thách thức của bài toán	3
1.5 Đóng góp - Kiểm tra lại	4
1.6 Bố cục của khóa luận	5
2 Các công trình liên quan	6
2.1 Giai đoạn 2022 - 2023	7
2.1.1 Gait Recognition with Mask-based Regularization (ReverseMask)shen2022gaitrecognitionwithmaskbasedregularization	
2.1.2 Gait Recognition in the Wild with Dense 3D Representations and A Benchmark (SMPLGait)zheng2022gaitrecognitioninthewildwithdense3drepresentationsandabenchmark	
2.1.3 GaitEdge: Beyond Plain End-to-end Gait Recognition for Better Practicality liang2022gaitedgeplainendtoendgaitrecognitionforbetterpracticality	

2.1.4	LidarGait: Benchmarking 3D Gait Recognition with Point Clouds	shen2023lidargaitbenchmarking3dgait	14
2.1.5	Hierarchical Spatio-Temporal Representation Learning (HSTL)	wang2023hierarchic spatiotemporalrepresentation	
3	Phương pháp đề xuất		18
3.1	Tổng quan về mô hình		19
3.2	Thay thế kỹ thuật ARME thành P3D	qiu2017learning spatiotemporalrepresentation	
3.2.1	Nguyên lý		20
3.2.2	Độ phức tạp tính toán		21
3.2.3	Tổng tham số của mô hình		22
3.2.4	Chi phí huấn luyện		22
3.3	Mô hình tạo sinh ảnh có kết hợp điều kiện không gian . .		23
3.3.1	Mô hình khuếch tán		23
3.3.2	Mô hình khuếch tán trong không gian tiềm ẩn . . .		24
3.3.3	ControlNet		24
4	Thực nghiệm		26
4.1	Mục tiêu thực nghiệm		26
4.2	Chi tiết quá trình huấn luyện		27
4.2.1	Tập dữ liệu huấn luyện		27
4.2.2	Quá trình tiền xử lý dữ liệu		27
4.2.3	Kết quả quá trình huấn luyện		28
4.3	Thử nghiệm mô hình tô màu tổng quát		29
4.3.1	Tập dữ liệu thử nghiệm		29
4.3.2	Kết quả thử nghiệm		30
4.4	Phân tích kết quả		30
5	Kết luận		32
5.1	Kết luận		32
5.2	Bàn luận		33

A	Phụ lục	34
A.1	Bảng đối chiếu thuật ngữ	34
A.2	Mã nguồn mẫu	34
A.3	Thông tin bổ sung	35

Danh sách hình vẽ

2.1	Lược đồ thời gian công bố các nghiên cứu tiêu biểu về nhận dạng dáng đi giai đoạn 2022–2023.	7
2.2	Sơ đồ phân loại các nghiên cứu về nhận dạng dáng đi theo các nhánh tiếp cận chính trong giai đoạn 2022–2023. . . .	8
2.3	Khung kiến trúc của ReverseMask.	9
2.4	Khung kiến trúc của SMPLGait.	11
2.5	Khung kiến trúc của GaitEdge.	12
2.6	Khung kiến trúc của LidarGait.	14
2.7	Khung kiến trúc của HSTL.	16
3.1	Tổng quan về mô hình tô màu ảnh độ xám dựa trên mô hình tổng hợp ảnh có điều kiện sử dụng quy trình khuếch tán. .	19
3.2	Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.	21
3.3	Kiến trúc của mô hình khuếch tán trong không gian tiềm ẩn (LDM).	24
3.4	Kiến trúc của ControlNet.	25
4.1	Chất lượng ảnh được tạo sinh trong quá trình huấn luyện. Ở lân cận bước thứ 3200, hiện tượng hội tụ đột ngột xảy ra.	29
4.2	Ví dụ kết quả tô màu. (a) Ảnh độ xám đầu vào. (b) Ảnh được tô màu bởi mô hình đề xuất. (c) Ảnh màu gốc để so sánh.	31

Danh sách bảng

4.1	Thống kê số lượng ảnh theo từng tập huấn luyện sau khi tiền xử lý.	28
4.2	Kết quả so sánh các mô hình tô màu tự động trên các tập dữ liệu đánh giá.	30
A.1	Phụ lục đối chiếu Việt Anh	34

Tóm tắt

Phần quy định chung khi trình bày báo cáo:

- Tất cả biểu thức toán phải được đánh số.
- Tất cả hình vẽ, bảng biểu phải có chú thích, và đánh dấu để tham chiếu trong mục lục.
- Hạn chế tối đa việc dùng tiếng anh, kể cả các thuật ngữ chuyên môn, có gắng dịch sang tiếng việt với từ ngữ dễ hiểu. Trong trường hợp quá khó để phiên dịch, được phép dùng tiếng anh, nhưng phải bổ sung ở bảng A.1 trong phần **Phụ lục**.
- Các tài liệu đính kèm phải theo một chuẩn duy nhất, không tham khảo loạn xạ. Có nhiều cách để lấy định dạng chuẩn, cách đơn giản nhất là tìm bài báo đó trên trang **arxiv**, tìm dòng **export BibTeX citation**, sao chép định dạng đó vào file **references.bib**.

Viết theo mẫu bên dưới

Tô màu ảnh độ xám là quá trình ước lượng các giá trị màu RGB cho từng điểm trong ảnh độ xám, nhằm chuyển đổi chúng thành ảnh màu. Tô màu ảnh độ xám được chia thành hai nhóm lớn: tô màu tự động và tô màu bán tự động. Tuy nhiên, hầu hết các mô hình hiện tại chỉ tập trung vào một phương thức duy nhất, điều này hạn chế tính năng mà người dùng mong muốn.

Trong nghiên cứu này, nhóm giới thiệu một mô hình tô màu ảnh độ xám kết hợp cả hai phương thức tự động và bán tự động (dựa trên lời

nhắc văn bản) được phát triển dựa trên kiến trúc mô hình ControlNet. ControlNet là một kiến trúc mạng nơ-ron được thiết kế nhằm tích hợp các điều kiện điều khiển không gian vào các mô hình tạo sinh ảnh từ văn bản đã được huấn luyện trước.

Nhóm đã tiến hành huấn luyện mô hình trên bốn tập dữ liệu cho các mục đích khác nhau. Sau đó nhóm tiến hành thử nghiệm mô hình tô màu chính trên ba tập dữ liệu đánh giá khác nhau. Kết quả đánh giá cho thấy, mô hình của nhóm đã vượt qua hầu hết các phương pháp tô màu tiên tiến trước đó trên phương thức tô màu tự động về chỉ số Colorfulness. Cuối cùng, nhóm xây dựng thêm một giao diện đơn giản để người dùng có thể sử dụng và ứng dụng các mô hình vào các công việc có liên quan đến tô màu ảnh độ xám.

Chương 1

Giới thiệu

Mục này được viết dựa trên các bài khảo sát (survey) để giới thiệu tổng quan về chủ đề lớn **Nhận dạng dáng đi** được nghiên cứu. Cách tổ chức nội dung bên dưới có thể tham khảo, hoặc chỉnh sửa tùy cho phù hợp ngữ cảnh.

1.1 Bối cảnh chung

Trong kỷ nguyên xây dựng các thành phố thông minh và xã hội số hóa hiện nay, hệ thống camera giám sát đã bùng nổ về số lượng và trở thành một phần không thể thiếu của hạ tầng an ninh công cộng. Với hàng triệu giờ chuỗi khung hình được ghi lại mỗi ngày, việc dựa vào sức người để theo dõi là bất khả thi, đặt ra nhu cầu cấp thiết về các hệ thống nhận diện tự động, thông minh để truy vết tội phạm và đảm bảo an toàn xã hội. Tuy nhiên, các phương pháp sinh trắc học truyền thống như vân tay hay móng mắt lại không thể áp dụng trong các tình huống giám sát thụ động từ xa.

Chính từ nhu cầu thực tiễn đó, Nhận dạng dáng đi đã nổi lên như một giải pháp tối ưu. Đây là kỹ thuật sinh trắc học hành vi nhằm xác định danh tính của cá nhân dựa trên dáng đi của con người. Bởi vì dáng đi được hình thành từ cấu trúc cơ xương độc nhất và thói quen vận động của mỗi người, tạo nên một dấu ấn riêng biệt có khả năng phân biệt cao.

Ngay từ những năm 1970, các nghiên cứu tâm lý học nền tảng của Cutting và Kozlowski đã chứng minh rằng con người có khả năng nhận diện người quen chỉ thông qua sự chuyển động của các điểm sáng mô phỏng dáng đi mà không cần bất kỳ thông tin chi tiết nào về ngoại hình hay khuôn mặt **Sarkar _ Gait _ Handbook _ 2008**.

1.2 Động lực

Động lực mạnh mẽ nhất thúc đẩy sự phát triển của nhận dạng dáng đi nằm ở khả năng nhận dạng tầm xa hoặc trong các điều kiện khó khăn. Trong khi các đặc điểm sinh trắc học vật lý như khuôn mặt, vân tay, móng mắt thường yêu cầu sự hợp tác của chủ thể, tiếp xúc gần, hoặc hình ảnh đầu vào có độ phân giải rất cao, thì dáng đi là đặc điểm sinh trắc học duy nhất có thể nhận diện được từ khoảng cách xa hàng chục mét và ngay cả trong điều kiện hình ảnh chất lượng thấp. Điều này cho phép hệ thống xác định danh tính đối tượng ngay cả khi họ quay lưng lại với camera, che mặt, hoặc bị khuất trong đám đông, biến nó thành công cụ lý tưởng cho các hệ thống giám sát thông minh mà không cần đối tượng phải tương tác trực tiếp với thiết bị.

Bên cạnh lợi thế về khoảng cách, tính chất khó ngụy trang và khả năng thu thập thụ động cũng là những yếu tố then chốt tạo nên sức hấp dẫn của lĩnh vực này. Dáng đi của một người được định hình bởi cấu trúc cơ xương và thói quen vận động ăn sâu qua thời gian, do đó rất khó để một cá nhân có thể thay đổi hoặc làm giả dáng đi của mình một cách tự nhiên trong thời gian dài, khác hẳn với việc dễ dàng đeo mặt nạ hay găng tay để che giấu khuôn mặt và vân tay. Hơn nữa, với sự bùng nổ của hạ tầng camera quan sát hiện nay, dữ liệu dáng đi có sẵn ở khắp mọi nơi và có thể được thu thập liên tục 24/7 một cách thụ động, tạo điều kiện thuận lợi to lớn cho các ứng dụng thực tế trong điều tra tội phạm, an ninh công cộng và y tế.

1.3 Phát biểu bài toán

Bài toán nhận dạng dáng đi có thể được định nghĩa là một bài toán truy xuất người dựa trên dữ liệu video. Mục tiêu là khớp một chuỗi hình ảnh dáng đi đầu vào với một cơ sở dữ liệu các mẫu đã biết để xác định danh tính.

- **Đầu vào:** Chuỗi các khung hình dáng đi được thu thập từ các nguồn như camera RGB, camera hồng ngoại, cảm biến chiều sâu hoặc Li-DAR đã được nhị phân sau tách nền.

$$\mathbf{S_P} = \{\mathbf{S_P}(1), \mathbf{S_P}(2), \dots, \mathbf{S_P}(M)\}$$

với M là số lượng khung hình trong chuỗi.

- **Đầu ra:** Danh tính của người trong video hoặc điểm số tương đồng cao nhất khi so khớp chuỗi đầu vào với các chuỗi mẫu đã lưu trong cơ sở dữ liệu ($\mathbf{S_G}$).

Mỗi chuỗi con thăm dò $\mathbf{S_{P_k}}$ được so khớp với chuỗi thư viện $\mathbf{S_G}$ thông qua phép tương quan chéo:

$$\text{Corr}(\mathbf{S_{P_k}}, \mathbf{S_G})(l) = \sum_{j=1}^{N_{Gait}} S(\mathbf{S_P}(k+j), \mathbf{S_G}(l+j)) \quad (1.1)$$

Tính toán độ tương đồng tổng thể giữa chuỗi thăm dò và chuỗi thư viện.

$$\text{Sim}(\mathbf{S_P}, \mathbf{S_G}) = \text{Median}_k \left(\max_l \text{Corr}(\mathbf{S_{P_k}}, \mathbf{S_G})(l) \right) \quad (1.2)$$

1.4 Thách thức của bài toán

Mặc dù đã đạt được những bước tiến lớn, nhận dạng dáng đi vẫn phải đối mặt với nhiều thách thức nghiêm trọng khi triển khai trong môi trường

thực tế. Các yếu tố ngoại cảnh gây nhiễu, như sự thay đổi góc nhìn của camera, đây được xem là yếu tố gây nhiễu lớn nhất làm thay đổi hình dạng hình học của đối tượng trên khung hình.

Các loại trang phục khác nhau như áo khoác dày làm biến dạng hình dáng cơ thể, việc mang vác đồ vật, và sự thay đổi tốc độ đi bộ đều làm giảm đáng kể độ chính xác của hệ thống.

Đặc biệt, sự thay đổi về bề mặt đi bộ ví dụ từ cỏ sang bê tông và khoảng cách thời gian dài giữa các lần thu thập dữ liệu (trên 6 tháng) là những bài toán cực kỳ khó khăn do dáng đi của con người có xu hướng thay đổi tự nhiên theo thời gian hoặc điều kiện địa hình.

Bên cạnh đó, các vấn đề về quyền riêng tư và đạo đức khi thu thập dữ liệu từ xa **shen2023comprehensivesurveydeepgait** mà không có sự đồng ý của đối tượng, cùng với áp lực về tài nguyên tính toán để xử lý video thời gian thực trên quy mô lớn, vẫn là những rào cản cần được giải quyết để công nghệ này có thể phổ biến rộng rãi.

1.5 Đóng góp - **Kiểm tra lại**

Trong báo cáo này, mục tiêu chính là nghiên cứu và cải tiến mô hình nhận dạng dáng đi dựa trên kiến trúc phân cấp không gian - thời gian (HSTL). Những đóng góp chính bao gồm:

Về mặt lý thuyết:

- Đề xuất kiến trúc HSTL tối ưu bằng cách thay thế mô-đun trích xuất đặc trưng ARME bằng khối Pseudo-3D (P3D), giúp giảm đáng kể số lượng tham số và chi phí tính toán trong khi vẫn đảm bảo hiệu quả trích xuất đặc trưng không gian - thời gian
- Cải tiến không gian đặc trưng với hàm mất mát Circle Loss thay thế cho Triplet Loss, giúp tăng cường khả năng phân biệt của mô hình đối với các mẫu khó và cải thiện tốc độ hội tụ.

Về mặt thực tiễn:

- Xây dựng, huấn luyện và kiểm thử thành công mô hình cải tiến trên bộ dữ liệu chuẩn CASIA-B, chứng minh hiệu quả so với mô hình gốc.
- Tạo ra một mô hình nhận dạng đáng đi có độ phức tạp tính toán thấp, đạt được sự cân bằng hiệu quả giữa độ chính xác và chi phí tài nguyên, phù hợp cho việc triển khai trên các hệ thống có cấu hình phần cứng hạn chế.

1.6 Bố cục của khóa luận

Báo cáo khóa luận bao gồm năm chương: Chương 1 trình bày bối cảnh, động lực nghiên cứu và phát biểu bài toán; Chương 2 trình bày các công trình nghiên cứu liên quan; Chương 3 trình bày chi tiết phương pháp đề xuất; Chương 4 trình bày kết quả thực nghiệm; Chương 5 trình bày kết luận và hướng phát triển.

Chương 2

Các công trình liên quan

Mục này đi sâu hơn vào các nghiên cứu/phương pháp cho chủ đề **Nhận dạng đáng đi**. Gợi ý:

- Phần lớn nội dung mục này dựa trên các bài tổng hợp/khảo sát.
- Liệt kê tất cả các phương pháp đến thời điểm hiện tại **2026**. Một số cách trình bày (chắc chắn được dùng trong các bài tổng hợp, nên tham khảo kỹ):
 - Vẽ lược đồ thời gian công bố của các nghiên cứu.
 - Vẽ sơ đồ chia các nghiên cứu theo các nhánh tiếp cận chính.
- Từng nhánh tiếp cận bài toán sẽ trình bày sâu hơn trong từng mục nhỏ:
 - Liệt kê theo trình tự thời gian
 - Trình ý tưởng/nguyên lý của từng nghiên cứu được đề cập.
 - Kết luận bằng điểm mạnh và hạn chế chung của nhóm các phương pháp.
- **Lưu ý:** Khi trình bày đến nhánh tiếp cận chính (có chứa nghiên cứu được chọn (HSTL)), nên trình bày nhiều hơn cả về điểm mạnh (ngầm

ý đây là phương pháp được quan tâm) và điểm yếu (ngầm ý đóng góp của nghiên cứu này).

- Đối với các nhánh tiếp cận hoặc nghiên cứu vượt trội nghiên cứu được chọn ([HSTL](#)) về hiệu năng, hãy nói rõ hạn chế lớn của chúng. Quan trọng hơn hết, hãy trung thực về lý do không lựa chọn đào sâu, ví dụ, chi phí (huấn luyện, lưu trữ dữ liệu) lớn ([gần như là điều hiển nhiên khi chi phí lớn sẽ cho hiệu năng lớn](#)), [năng lực nghiên cứu hạn chế của nhóm](#), ...
- Để người đọc dễ tiếp cận, nên chèn thêm các hình vẽ minh họa về dữ liệu của từng nhánh tiếp cận.
- **Nội dung có sẵn khá lan man, không nên viết theo.**

2.1 Giai đoạn 2022 - 2023


Trong giai đoạn từ năm 2022 đến 2023, nhận dạng dáng đi đã chứng kiến sự phát triển đa dạng về cả kỹ thuật trích xuất đặc trưng lẫn các phương thức biểu diễn dữ liệu mới. Để cung cấp cái nhìn tổng quan về tiến trình phát triển và mối quan hệ giữa các công trình nghiên cứu tiêu biểu, chúng tôi tiến hành hệ thống hóa các tài liệu khảo sát theo hai khía cạnh: trình tự thời gian công bố và hướng tiếp cận kỹ thuật.



Hình 2.1: Lược đồ thời gian công bố các nghiên cứu tiêu biểu về nhận dạng dáng đi giai đoạn 2022–2023.

Cụ thể, Hình 2.1 minh họa tiến trình phát triển của các nghiên cứu tiêu biểu, trải dài từ các phương pháp xử lý dựa trên lưới ba chiều và mô

hình SMPL vào đầu năm 2022 cho đến sự xuất hiện của các kiến trúc học sâu phân cấp và các phương pháp xử lý đám mây điểm LiDAR vào năm 2023.



Hình 2.2: Sơ đồ phân loại các nghiên cứu về nhận dạng dáng đi theo các nhánh tiếp cận chính trong giai đoạn 2022–2023.


Bên cạnh đó, Hình 2.2 trình bày sơ đồ phân loại các nghiên cứu này thành hai nhánh tiếp cận chủ đạo. Nhánh thứ nhất tập trung vào học đầu-cuối và học đặc trưng nhằm tối ưu hóa khả năng biểu diễn trên dữ liệu video hoặc ảnh biên dạng. Nhánh thứ hai khai thác các biểu diễn ba chiều, tận dụng thông tin hình học không gian để nâng cao độ tin cậy của mô hình trong các điều kiện phức tạp.

2.1.1 Gait Recognition with Mask-based Regularization (ReverseMask)shen2022gaitrecognitionmaskbased

Các phương pháp phổ biến trước thường chia cơ thể người thành các phần nhỏ theo chiều ngang. Tuy nhiên, cách chia cứng nhắc này làm mất liên kết thông tin tại các đường ranh giới giữa các phần.

Dữ liệu dáng đi thường ít và hình ảnh dáng đi chứa ít thông tin. Các mạng nơ-ron sâu dễ bị ghi nhớ quá mức các đặc trưng cục bộ nổi trội như phần đầu hoặc chân mà bỏ qua cấu trúc tổng thể, dẫn đến khả năng tổng quát hóa kém.

Ý tưởng của ReverseMask: Sử dụng cơ chế điều chuẩn dựa trên mặt nạ để tiêm nhiễu vào bản đồ đặc trưng. Thay vì chỉ xóa bỏ đặc trưng, phương pháp này tạo ra nhiễu bằng cách vừa xóa vừa thay đổi tỷ lệ đặc trưng, buộc mô hình phải học cả các chi tiết tinh tế và cấu trúc tổng thể.



Hình 2.3: Khung kiến trúc của ReverseMask.

Hình 2.3 chính là khung kiến trúc của ReverseMask. Phần trên là mô hình cơ sở đơn giản hóa, trong khi phần dưới gồm bốn khối có thể thay thế. TP, FC, HP và BN lần lượt biểu thị lớp gộp theo thời gian, lớp kết nối đầy đủ, lớp gộp theo phương ngang và lớp chuẩn hóa theo lô. Conv là lớp tích chập kết hợp với Leaky ReLU. RM là lớp ReverseMask được đề xuất nhằm đưa nhiễu vào bản đồ đặc trưng, và RMFE là lớp trích xuất đặc trưng chuyên biệt cho ReverseMask.

Điểm mạnh:

- Đạt hiệu suất vượt trội trên các bộ dữ liệu chuẩn CASIA-B, OU-MVLP, đặc biệt trong điều kiện thay đổi trang phục, nhờ khắc phục triệt để sự gián đoạn thông tin tại vùng biên của các mô hình chia phần truyền thống.
- Thông qua kiến trúc Inception-like ba nhánh, mô hình vừa học được

chi tiết tinh tế vừa nắm bắt cấu trúc tổng thể, giúp giảm thiểu hiện tượng quá khớp và tăng cường khả năng tổng quát hóa.

- Có tính linh hoạt cao, dễ dàng tích hợp để cải thiện các mạng có sẵn và giúp quá trình huấn luyện ổn định hơn

Hạn chế:


- Việc triển khai khối Inception-like với ba nhánh song song, đồng nghĩa với việc gia tăng số lượng tham số và khối lượng tính toán trong quá trình huấn luyện và suy diễn.
- Hiệu quả của mô hình phụ thuộc vào các tham số như p (tỉ lệ diện tích mặt nạ) và các hệ số nhiễu α, β .
- Chỉ hoạt động tốt với ảnh dạng bóng, ít thông tin. Đối với các loại dữ liệu khác như ảnh RGB giàu thông tin, thì phương pháp này cần điều chỉnh hoặc không hiệu quả bằng.

2.1.2 Gait Recognition in the Wild with Dense 3D Representations and A Benchmark (SMPLGait)zheng

Các phương pháp cũ chủ yếu dựa trên dữ liệu 2D như hình dáng, hình bóng hoặc khung xương 2D. Tuy nhiên, trong môi trường thực tế, việc chiếu cơ thể người 3D lên mặt phẳng 2D sẽ làm mất đi nhiều thông tin quan trọng như góc nhìn, hình dạng và động lực học

Ý tưởng của SMPLGait: Sử dụng biểu diễn 3D dày đặc thông qua mô hình SMPL để khôi phục thông tin về hình dạng và góc nhìn trong không gian 3D. Kết hợp thông tin này để chuẩn hóa các đặc trưng bề ngoài từ các góc nhìn khác nhau về một không gian đặc trưng thống nhất, giúp nhận diện chính xác hơn bất kể góc quay camera.

Điểm mạnh:



Hình 2.4: Khung kiến trúc của SMPLGait.


- Nhờ vào các tham số góc nhìn 3D từ mô hình SMPL, SMPLGait có thể chuẩn hóa định hướng của cơ thể người trong các tình huống khớp nối đa góc nhìn.
- SMPLGait vượt trội hơn hẳn các phương pháp 2D SOTA như GaitSet, GaitPart trên tập dữ liệu Gait3D đầy thách thức. Khả năng xử lý tốt các trường hợp bị che khuất và góc nhìn cực đoan cũng cao hơn nhờ thông tin hình học từ lưới 3D.

Hạn chế:

- Mô hình hiện tại chủ yếu tập trung vào đặc trưng không gian. Các thông tin về vận động theo thời gian chưa được khai thác triệt để, mặc dù đây là yếu tố quan trọng trong nhận dạng dáng đi.
- Hiệu quả của SMPLGait phụ thuộc nhiều vào mô hình khôi phục 3D. Nếu việc ước lượng tham số SMPL từ ảnh 2D bị sai do ảnh mờ, quá tối, hiệu suất nhận dạng sẽ giảm.
- Độ phức tạp tính toán lớn do phải chạy thêm một mô hình khôi phục 3D song song với mạng nhận dạng.

2.1.3 GaitEdge: Beyond Plain End-to-end Gait Recognition for Better Practicality liang2022gaitedgeplainen

Các phương pháp học đầu-cuối trước đây thường trích xuất đặc trưng trực tiếp từ ảnh RGB hoặc thông qua các mặt nạ phân đoạn dạng số thực. Mặc dù các phương pháp này đạt hiệu quả tốt trong cùng một miền dữ liệu, nhưng trên thực tế mô hình có xu hướng ghi nhớ quá mức các đặc trưng không liên quan trực tiếp đến dáng đi, chẳng hạn như màu sắc trang phục hoặc họa tiết bề mặt, thay vì học các đặc trưng động học của dáng đi. Điều này dẫn đến sự suy giảm đáng kể hiệu năng khi đánh giá trên các tập dữ liệu khác miền.



Hình 2.5: Khung kiến trúc của GaitEdge.

Ý tưởng của GaitEdge: Phương pháp đề xuất tổng hợp một dạng bóng dáng nhân tạo, trong đó phần biên của cơ thể được biểu diễn dưới dạng giá trị số thực có thể huấn luyện nhằm bảo toàn thông tin hình dáng chi tiết, trong khi phần bên trong và vùng nền được ràng buộc về dạng

nhị phân hoặc bị loại bỏ để hạn chế các nhiễu liên quan đến màu sắc và kết cấu bề mặt.

Điểm mạnh:


- GaitEdge đạt hiệu suất cao nhất trong các thí nghiệm đánh giá chéo giữa các tập dữ liệu khác nhau (ví dụ từ CASIA-B sang TTG-200), nhờ khả năng loại bỏ hiệu quả các nhiễu RGB vốn không ổn định giữa các môi trường
- Bằng cách giới hạn quá trình huấn luyện chủ yếu tại vùng biên của bóng dáng, mô hình được buộc phải tập trung vào các đặc trưng đáng đi tinh vi, thay vì phụ thuộc vào các đặc trưng ngoại hình thô như màu sắc trang phục hoặc vật mang theo.
- Mô-đun GaitAlign giúp hệ thống duy trì hoạt động ổn định trong các điều kiện thực tế, nơi việc phát hiện người không hoàn hảo, qua đó cải thiện đáng kể độ chính xác trung bình.

Hạn chế:

- Trong huấn luyện và kiểm thử trên cùng một tập dữ liệu, GaitEdge có độ chính xác thấp hơn khoảng 2% so với các mô hình học đầu-cuối thuần túy, do việc loại bỏ một phần thông tin nội tại của bóng dáng làm suy giảm một số đặc trưng hữu ích trong cùng điều kiện môi trường.
- Hiệu suất tổng thể của phương pháp vẫn phụ thuộc vào chất lượng của mạng phân đoạn ban đầu, vốn chịu trách nhiệm cung cấp hình dáng ban đầu của đối tượng.
- Khả năng tổng quát hóa khác miền nhạy cảm với kích thước vùng biên được sử dụng, trong đó việc mở rộng vùng cạnh quá mức có thể dẫn đến suy giảm hiệu suất.

2.1.4 LidarGait: Benchmarking 3D Gait Recognition with Point Clouds

Các phương pháp nhận diện dáng đi truyền thống thường dựa vào hình ảnh RGB hoặc bóng đen 2D. Tuy nhiên, cách tiếp cận này gặp khó khăn lớn trong môi trường thực tế do thiếu thông tin cấu trúc 3D của cơ thể người và dễ bị nhiễu bởi ánh sáng yếu, quần áo tiếp màu nền, hoặc nền phức tạp.



Hình 2.6: Khung kiến trúc của LidarGait.

Ý tưởng của LidarGait: Thay vì trích xuất đặc trưng trực tiếp từ tập điểm thừa thớt như các mạng PointNet thường làm cho bài toán phân loại vật thể, LidarGait chiếu đám mây điểm 3D thành các bản đồ độ sâu dưới dạng hình ảnh 2D. Sau đó, phương pháp này tận dụng các kiến trúc CNN tiêu chuẩn dành cho biểu diễn không gian hai chiều để trích xuất đặc trưng dáng đi.

Điểm mạnh:

- LidarGait vượt trội hơn camera RGB trong môi trường ngoài trời, đặc biệt là vào ban đêm hoặc điều kiện ánh sáng yếu, nơi mà các thuật toán phân đoạn hình ảnh thường thất bại.

- Không bị ảnh hưởng bởi việc thay đổi quần áo hoặc màu sắc quần áo trùng với phong nền, vì LidarGait thu thập dữ liệu hình học chứ không phải màu sắc.
- LidarGait duy trì hiệu suất nhận dạng rất ổn định ngay cả khi góc nhìn thay đổi mạnh, nhờ vào việc giữ được cấu trúc 3D thực của cơ thể người.

Hạn chế:


- LidarGait gặp khó khăn khi đối tượng cầm ô, vì ô thường được giữ lại trong đám mây điểm và gây nhiễu cho việc tính toán cấu trúc cơ thể, trong khi các thuật toán camera thường xóa bỏ phần này trong quá trình phân đoạn.
- Hiện tại LidarGait chủ yếu chỉ sử dụng một loại dữ liệu đầu vào là đám mây điểm 3D.
- Mật độ của đám mây điểm phụ thuộc vào khoảng cách của đối tượng đến cảm biến, điều này vẫn có tác động nhất định đến hiệu suất nhận dạng.

2.1.5 Hierarchical Spatio-Temporal Representation Learning (HSTL) wang2023hierarchicalspatiotemporalrepres

Các phương pháp nhận diện dáng đi hiện tại thường chia cắt hình ảnh cơ thể thành các phần cố định chẳng hạn như cắt ngang thành 8 hoặc 16 phần,... để trích xuất đặc trưng. Tuy nhiên, cách làm này bỏ qua mối quan hệ phân cấp tự nhiên của cơ thể người khi chuyển động. Ví dụ: chuyển động của bàn chân và cẳng chân có liên quan mật thiết với nhau, và chúng lại là một phần của chuyển động thân dưới.

Ý tưởng của HSTL: Thay vì xem xét các bộ phận cơ thể một cách rời rạc, HSTL học các đặc trưng dáng đi theo cấu trúc phân cấp từ thô

đến tinh. Cụ thể, mô hình khai thác mối quan hệ phụ thuộc giữa các bộ phận cơ thể như đầu, thân, chân và tay ở nhiều mức độ khác nhau, từ biểu diễn toàn bộ cơ thể cho đến các vùng chi tiết cục bộ.



Hình 2.7: Khung kiến trúc của HSTL.

Trong hình 2.7 chính là khung kiến trúc của HSTL. Phương pháp này chủ yếu bao gồm ba mô-đun: ARME (bộ trích xuất chuyển động dựa trên vùng thích ứng), ASTP (gộp không gian–thời gian thích ứng) và FTA (tổng hợp theo thời gian ở mức khung hình). Trong giai đoạn tiền xử lý, một cấu trúc phân cấp của dáng đi được xây dựng nhằm định hướng thiết kế kiến trúc của HFSL. Khung mô hình sử dụng nhiều ARME để trích xuất đặc trưng dáng đi từ toàn bộ cơ thể đến các vùng riêng lẻ. Mô-đun ASTP thực hiện ánh xạ đặc trưng phân cấp cho đầu ra của từng mức ARME. Mô-đun FTA nén các đoạn cục bộ của mỗi chuỗi dáng đi nhằm giảm số lượng khung hình dư thừa. Các ký hiệu T , H và W lần lượt biểu thị các chiều của bản đồ đặc trưng. Ký hiệu © biểu thị phép nối.

Điểm mạnh:

- HSTL đạt kết quả tốt nhất trên các bộ dữ liệu quy mô lớn như CASIA-B, OUMVLP, GREW và Gait3D. Phương pháp này đặc biệt

hiệu quả trong các điều kiện thách thức, chẳng hạn như thay đổi trang phục và mang vác. Ngoài ra, HSTL vẫn duy trì hiệu suất ổn định trong môi trường thực tế, nơi tồn tại nhiều nhiễu do sai lệch căn chỉnh cơ thể và sự xuất hiện của vật cản.

- So với các phương pháp sử dụng mạng tích chập 3D có độ phức tạp cao như GaitGL và 3D Local, HSTL đạt được sự cân bằng tốt hơn giữa độ chính xác và chi phí tính toán. Kiến trúc phân cấp của HSTL giúp hạn chế các phép tích chập 3D dư thừa, từ đó giảm đáng kể độ phức tạp tính toán.
- Mô-đun FTA giúp mô hình thích ứng tốt với sự thay đổi về tốc độ đi và sự dư thừa khung hình. Module ARME cho phép học các đặc trưng chuyển động riêng biệt cho từng vùng cơ thể thay vì gộp chung.
- Cải thiện đáng kể độ chính xác nhận dạng đối với trẻ em (nhóm đối tượng thường có dữ liệu ít hơn người lớn).

Hạn chế:

- Mặc dù đã được tối ưu so với các phương pháp trước đó, ARME vẫn dựa trên các phép tích chập 3D. Do phải đồng thời mô hình hóa cả không gian và thời gian, các toán tử này vẫn đòi hỏi chi phí tính toán quá lớn so với các mạng tích chập 2D.
- Là một phương pháp dựa trên ngoại hình và sử dụng bóng dáng làm đầu vào, mô hình vẫn chịu ảnh hưởng khi quá trình phân đoạn ban đầu không chính xác, đặc biệt trong các điều kiện môi trường phức tạp.

Chương 3


Phương pháp đề xuất

Mục này có cách viết đơn giản nhất là sẽ trình bày lại gần như đầy đủ các nội dung của phương pháp được chọn, nhưng những phần hạn chế sẽ được thay thế bằng các cải tiến do nhóm đề xuất. Cụ thể:

- Vẽ lại sơ đồ phương pháp đề xuất với các thành phần cải tiến được đề xuất.
- Đối với cải tiến khối **Conv3D**, báo cáo này không trình bày lại, mà trình bày thẳng về khối **Pseudo 3D**. Bên cạnh đó, bổ sung các so sánh lý thuyết giữa kỹ thuật đề xuất so với kỹ thuật gốc (khác biệt về nguyên lý, độ phức tạp thuật toán, chi phí huấn luyện, tổng tham số của mô hình lớn,...)
- Tương tự với **Circle Loss**.
- Tất cả các hình vẽ về các kỹ thuật hay phương pháp đề xuất, phải được chèn vào.
- Nội dung có sẵn khá lan man, không nên viết theo.

3.1 Tổng quan về mô hình

Hình 3.1 thể hiện quy trình huấn luyện tổng quát của mô hình, quy trình này bao gồm 2 giai đoạn:



Hình 3.1: Tổng quan về mô hình tô màu ảnh độ xám dựa trên mô hình tổng hợp ảnh có điều kiện sử dụng quy trình khuếch tán.

- **Giai đoạn 1:** Thiết lập tín hiệu điều khiển thông qua câu hướng dẫn và ảnh độ xám đầu vào. Mô hình sử dụng bộ mã hóa văn bản $\mathcal{E}_p$ của CLIP Radford_CLIP_2021 để mã hóa các lời nhắc văn bản được tạo ra bởi mô hình BLIP blip. Mô hình tích hợp một mạng mã hóa điều kiện $\mathcal{E}_c$ để trích xuất đặc trưng từ ảnh điều kiện trước khi đưa vào ControlNet ControlNet.
- **Giai đoạn 2:** Quá trình khuếch tán có kết hợp điều kiện không gian. Ảnh màu mục tiêu được mã hóa vào không gian tiềm ẩn bằng

bộ mã hóa $\mathcal{E}$ và được thêm các nhiễu Gauss qua T bước, sau đó được đưa vào cả 2 khối ControlNet **ControlNet** và Stable Diffusion **LDM_Rombach_Blattmann_Lorenz_Esser_Ommer_2022** cho quá trình khử nhiễu có điều kiện.

3.2 Thay thế kỹ thuật ARME thành P3D

3.2.1 Nguyên lý

Xét một thao tác tích chập trên một vùng cơ thể thứ j tại cấp độ l . Giả sử đầu vào là tensor $X \in \mathbb{R}^{C_{in} \times T \times H \times W}$. Bộ lọc có kích thước không gian $k \times k$ và thời gian d .

P3D tách một nhân 3D kích thước $d \times k \times k$ thành hai nhân riêng biệt: một nhân không gian ($1 \times k \times k$) và một nhân thời gian ($d \times 1 \times 1$). Theo cơ chế như sau:

- Nhân không gian (S): Sử dụng bộ lọc kích thước $1 \times k \times k$, tương đương với mạng nơ-ron tích chập 2D để học các đặc trưng hình ảnh.
- Nhân thời gian (T): Sử dụng các bộ lọc $d \times 1 \times 1$ để xây dựng các kết nối thời gian giữa các bản đồ đặc trưng liền kề.

Ta thực hiện tuần tự, thay vì tính toán trực tiếp như trong ARME:


$$Y_{Spatial} = S(X_j) = W_S * X_j \quad (\text{Nhân } 1 \times k \times k)$$

$$Y_j = T(Y_{Spatial}) = W_T * Y_{Spatial} \quad (\text{Nhân } d \times 1 \times 1)$$

Trong đó $W_S \in \mathbb{R}^{C_{out} \times C_{in} \times 1 \times k \times k}$ và $W_T \in \mathbb{R}^{C_{out} \times C_{out} \times d \times 1 \times 1}$.

Trong nghiên cứu này, chúng tôi áp dụng cấu trúc của P3D-A. Cụ thể là thành phần thời gian (T) đi trực tiếp sau thành phần không gian (S) trên cùng một đường dẫn. Đầu ra của không gian là đầu vào của thời gian.

$$x_{t+1} = (I + T \cdot S) \cdot x_t = x_t + T(S(x_t))$$



P3D-A

Hình 3.2: Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.

3.2.2 Độ phức tạp tính toán

Ở mô-đun ARME trong HSTL, các đặc trưng chuyển động được trích xuất thông qua các bộ lọc tích chập 3D với kích thước $3 \times 3 \times 3$. Điều này đòi hỏi số lượng phép tính dấu phẩy động lớn do phải xử lý đồng thời thông tin không gian và thời gian. Trong khi đó, P3D cải tiến giải quyết vấn đề này bằng cách phân rã phép tích chập 3D thành hai thao tác tuần tự: tích chập không gian 2D ($1 \times k \times k$) và tích chập thời gian 1D ($d \times 1 \times 1$). Về mặt lý thuyết, tỷ lệ giảm thiểu khối lượng tính toán R_{comp} được ước lượng như sau:

$$R_{comp} = \frac{\text{Chi phí}_{3D}}{\text{Chi phí}_{P3D}} \approx \frac{d \cdot k \cdot k}{(1 \cdot k \cdot k) + (d \cdot 1 \cdot 1)} = \frac{3 \cdot 3 \cdot 3}{9 + 3} = \frac{27}{12} \approx 2.25$$

Như vậy cho thấy P3D đã giúp giảm độ phức tạp tính toán khoảng 2.25 lần so với kỹ thuật ARME đã dùng trước đó, giúp tăng tốc độ suy luận của hệ thống.

3.2.3 Tổng tham số của mô hình

Một trong những thách thức lớn nhất của kiến trúc HSTL là sự gia tăng số lượng tham số do đặc thù sử dụng các bộ lọc tích chập độc lập cho từng vùng cơ thể. Do đó, việc tối ưu hóa cấu trúc nhân tại mô-đun này sẽ mang lại hiệu quả giảm tải trực tiếp cho toàn bộ mô hình.

Đối với mô-đun ARME, việc sử dụng tích chập 3D thuần túy đồng nghĩa với việc mỗi nhân phải học một khối trọng số kích thước $3 \times 3 \times 3$, tương đương với 27 tham số cho mỗi kênh đặc trưng trên mỗi vùng cơ thể. Khi số lượng vùng cơ thể K tăng lên để trích xuất đặc trưng chi tiết hơn, tổng lượng tham số của mô hình sẽ vô cùng lớn, dẫn đến nguy cơ quá khớp cao và kích thước tệp lưu trữ lớn.

Ngược lại, kiến trúc P3D đề xuất tiếp cận vấn đề bằng cách phân rã nhân 3D thành hai thành phần trực giao: một bộ lọc không gian kích thước $1 \times 3 \times 3$ và một bộ lọc thời gian kích thước $3 \times 1 \times 1$. Tổng số tham số cần thiết cho cấu trúc tách biệt này chỉ là $9 + 3 = 12$ tham số.

Như vậy, ta có thể thấy kiến trúc đề xuất giúp loại bỏ khoảng 55.6% lượng tham số dư thừa tại các lớp tích chập $((27 - 12)/27)$. Sự tinh giản này giúp HSTL trở nên gọn nhẹ hơn đáng kể, đồng thời đóng buộc mô hình phải học các đặc trưng cốt lõi hiệu quả hơn thay vì ghi nhớ nhiều từ dữ liệu huấn luyện.

3.2.4 Chi phí huấn luyện

Mặc dù P3D tách biệt các thành phần không gian và thời gian, việc tích hợp các kết nối tắt trong khối P3D giúp quá trình lan truyền ngược đạo hàm diễn ra hiệu quả hơn so với mạng tích chập 3D thuần túy. Nhờ đó, mô hình đạt được khả năng hội tụ ổn định hơn, ngay cả khi độ sâu của mạng được gia tăng.

Nhờ số lượng tham số được giảm đáng kể, mô hình đề xuất tiêu thụ ít bộ nhớ đồ họa hơn trong quá trình lan truyền ngược. Điều này cho phép sử dụng kích thước lô huấn luyện lớn hơn trên cùng một cấu hình phần

cứng. Trong các bài toán học đo lường, chẳng hạn như nhận dạng dáng đi, việc sử dụng kích thước lớn đóng vai trò then chốt, giúp mô hình học được các mẫu khó hiệu quả hơn, từ đó gián tiếp cải thiện độ chính xác.

3.3 Mô hình tạo sinh ảnh có kết hợp điều kiện không gian

Mô hình được đề xuất dựa trên mô hình khuếch tán có kết hợp điều kiện được phát triển qua các giai đoạn:

- Sự ra đời và phát triển của mô hình khuếch tán trong lĩnh vực tạo sinh ảnh.
- Quá trình điều chỉnh nhằm giảm độ phức tạp tính toán bằng cách đưa các tài nguyên huấn luyện vào không gian tiềm ẩn **LDM_Rombach_Blattman**
- ControlNet **ControlNet** ra đời để kết hợp các điều kiện kiểm soát không gian vào các mô hình khuếch tán đã được huấn luyện sẵn.

3.3.1 Mô hình khuếch tán

Mô hình khuếch tán là một lớp mô hình sinh dữ liệu, được thiết kế để mô phỏng các phân phối dữ liệu phức tạp thông qua việc đảo ngược quá trình khuếch tán. Lấy cảm hứng từ vật lý thống kê phi cân bằng **theoretical_framework_of_dm**, các mô hình này định nghĩa quá trình sinh dữ liệu như một chuỗi khử nhiễu dần dần.

Quá trình khuếch tán tiến được định nghĩa như sau:

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \quad (3.1)$$

Trong đó β_t là lịch trình nhiễu tại bước t . Mô hình được huấn luyện để dự đoán nhiễu ϵ :


$$\mathcal{L} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2] \quad (3.2)$$

3.3.2 Mô hình khuếch tán trong không gian tiềm ẩn

Mô hình khuếch tán trong không gian tiềm ẩn **LDM_Rombach_Blattmann** thực hiện quá trình khuếch tán trong không gian tiềm ẩn thay vì không gian điểm ảnh. Quá trình này bao gồm:

1. Mã hóa ảnh gốc $\mathbf{x}$ vào không gian tiềm ẩn: $\mathbf{z} = \mathcal{E}(\mathbf{x})$
2. Thực hiện khuếch tán trong không gian tiềm ẩn
3. Giải mã từ không gian tiềm ẩn: $\tilde{\mathbf{x}} = \mathcal{D}(\mathbf{z})$


Hình 3.3 minh họa kiến trúc của mô hình LDM.



Hình 3.3: Kiến trúc của mô hình khuếch tán trong không gian tiềm ẩn (LDM).

3.3.3 ControlNet

ControlNet **ControlNet** cho phép tích hợp các điều kiện không gian vào các mô hình khuếch tán đã được tiền huấn luyện. Kiến trúc của ControlNet được minh họa trong hình 3.4.



Hình 3.4: Kiến trúc của ControlNet.

ControlNet hoạt động bằng cách tạo một bản sao có thể huấn luyện của các khối encoder và middle block của U-Net, trong khi giữ nguyên các tham số của mô hình gốc. Các lớp tích chập khởi tạo bằng không đảm bảo rằng ở giai đoạn đầu của quá trình huấn luyện, ControlNet không ảnh hưởng đến mô hình gốc.

Chương 4

Thực nghiệm

Mục này tương đối đơn giản, chỉ cần liệt kê về tập dữ liệu, cài đặt chi tiết cho thực nghiệm, kế hoạch thực nghiệm, kết quả thực nghiệm so với nghiên cứu gốc (baseline).

Ở mục phân tích kết quả, ngoài việc phân tích về sự cải thiện trên kết quả, cần xem xét các khía cạnh khác như:

- Thời gian huấn luyện ra mô hình cuối cùng (100K).
- Chi phí của quá trình con (ví dụ, 100 iterations mất bao lâu).
- Sự biến thiên của hàm mất mát, độ chính xác (dựa trên log, vẽ biểu đồ đường thì càng tốt).
- Phải phân tích các khía cạnh mà mô hình đề xuất bị kém đi, nguyên nhân nào gây ra (do cấu hình chưa tối ưu, hay đó là điều không thể tránh khỏi khi dùng kĩ thuật đó, hay do dữ liệu). Đề xuất một số cách khắc phục các hạn chế đó (dành cho phần hướng nghiên cứu tương lai).

4.1 Mục tiêu thực nghiệm

Nhóm tiến hành huấn luyện để tạo ra 4 mô hình cho các mục tiêu khác nhau. Một mô hình được huấn luyện để tô màu cho các trường hợp tổng

quát, 3 mô hình còn lại được huấn luyện trên các tập dữ liệu chuyên biệt.

Sau đó nhóm sử dụng các độ đo FID và Colorfulness để so sánh trong tác vụ tô màu tự động và sử dụng thêm CLIP score để so sánh trong tác vụ tô màu bán tự động.

4.2 Chi tiết quá trình huấn luyện

4.2.1 Tập dữ liệu huấn luyện

Nhóm huấn luyện các mô hình trên 4 tập dữ liệu:

- **ImageNet100k:** Tập dữ liệu do nhóm tạo ra bằng cách chọn ngẫu nhiên 100 ngàn ảnh từ tập dữ liệu huấn luyện ImageNet [russakovsky2015image](#). Tất cả ảnh được điều chỉnh về kích thước 512×512 .
- **Fashion Product Images:** Tập dữ liệu bao gồm 44,441 ảnh có kích thước chung 1800×2400 .
- **Furniture Image:** bao gồm 15,000 ảnh của 5 loại nội thất riêng biệt.
- **VN-celeb:** Bộ dữ liệu bao gồm 23105 khuôn mặt của 1020 người.

4.2.2 Quá trình tiền xử lý dữ liệu

Quy trình tiền xử lý dữ liệu gồm 3 bước:

1. **Lọc ảnh độ xám:** Lọc ra các ảnh độ xám, chỉ giữ lại ảnh màu. Ảnh được xem là ảnh độ xám khi:

$$E(Var(C_i, C_j)) = \frac{1}{3} \sum_{(i,j) \in \{(R,G),(G,B),(B,R)\}} Var(C_i - C_j) < t \quad (4.1)$$

Trong đó $t = 12$ là ngưỡng độ xám.

2. **Thay đổi độ phân giải:** Tất cả ảnh được điều chỉnh về kích thước 512×512 .
3. **Tạo sinh câu mô tả:** Sử dụng mô hình BLIPblip để tạo sinh câu mô tả cho ảnh màu.

Bảng 4.1 thể hiện số lượng ảnh của 4 tập dữ liệu sau khi tiền xử lý.

Tập dữ liệu	ImageNet100k	Fashion Product	Furniture Image	VN-celeb
Số lượng ảnh	97,590	38,284	13,525	22,284

Bảng 4.1: Thống kê số lượng ảnh theo từng tập huấn luyện sau khi tiền xử lý.

4.2.3 Kết quả quá trình huấn luyện

Nhóm trình bày kết quả trực quan của quá trình huấn luyện. Khi sử dụng các lớp tích chập khởi tạo bằng không, ở giai đoạn đầu, các ảnh màu được sinh ra ngẫu nhiên không giống với ảnh độ xám điều kiện. Sau một thời gian học, ở khoảng bước thứ 3100 trở đi, ảnh màu được sinh ra bắt đầu giống với ảnh điều kiện, đây là hiện tượng **hội tụ đột ngột** được giới thiệu bởi Zhang và các đồng nghiệp **ControlNet**.



Hình 4.1: Chất lượng ảnh được tạo sinh trong quá trình huấn luyện. Ở lân cận bước thứ 3200, hiện tượng **hội tụ đột ngột** xảy ra.

4.3 Thử nghiệm mô hình tô màu tổng quát

4.3.1 Tập dữ liệu thử nghiệm

Để đánh giá độ hiệu quả của mô hình, nhóm sử dụng 3 tập dữ liệu đánh giá:

- **Tập val5k:** chứa 5000 ảnh từ bộ dữ liệu đánh giá của ImageNet `russakovsky2015imagenetlargescalevisual`.

- **Tập ctest:** tập 10000 ảnh được đề xuất bởi Larson và các đồng nghiệp **larsson2017learningrepresentationsautomaticcolorization**.
- **Tập COCO-Stuff:** với 5000 ảnh từ bộ dữ liệu COCO-Stuff **coco-stuff**.

4.3.2 Kết quả thử nghiệm

Kết quả thực nghiệm đối với các mô hình tô màu tự động được thể hiện trong bảng 4.2. Các điểm số được in đậm thể hiện giá trị tốt nhất, các chỉ số được gạch chân thể hiện chỉ số tốt thứ hai.

Tập dữ liệu Độ đo	ImageNet (val5k)		ImageNet (ctest)		COCO-Stuff	
	FID↓	Colorfulness↑	FID↓	Colorfulness↑	FID↓	Colorfulness↑
CIC Zhang_Isola_Efros_2016	22.0860	37.0313	12.7651	37.5761	33.3418	37.6487
UGCColor zhang_real-time_2017	15.1777	27.0966	6.5466	27.8122	21.4010	28.4487
DeOldify DeOldify	10.5191	26.4827	4.2143	23.1538	13.4318	28.3779
DDColor kang2023ddcolorphotorealisticimagecolorization	5.5726	<u>42.8370</u>	2.6294	42.9575	7.2718	42.2919
Chúng tôi	10.4125	44.2871	6.8341	44.7854	10.4632	45.2589

Bảng 4.2: Kết quả so sánh các mô hình tô màu tự động trên các tập dữ liệu đánh giá.

Kết quả cho thấy, mô hình của nhóm đã vượt qua hầu hết các phương pháp tô màu tiên tiến trước đó trên phương thức tô màu tự động về chỉ số Colorfulness.

4.4 Phân tích kết quả

Hình 4.2 minh họa một số kết quả tô màu của mô hình đề xuất.



(a) Ảnh đầu vào



(b) Kết quả tô màu



(c) Ảnh gốc

Hình 4.2: Ví dụ kết quả tô màu. (a) Ảnh độ xám đầu vào. (b) Ảnh được tô màu bởi mô hình đề xuất. (c) Ảnh màu gốc để so sánh.

Chương 5

Kết luận

Tổng kết lại đóng góp của nghiên cứu, các cải tiến, và hạn chế, kèm theo hướng nghiên tương lai (đã đề cập ở phần **Phân tích kết quả** của 4).

5.1 Kết luận

Trong đề tài này, nhóm đã nghiên cứu và phát triển một mô hình tô màu ảnh độ xám dựa trên mô hình khuếch tán. Nguyên lý thêm nhiễu và khử nhiễu của mô hình khuếch tán, kèm thêm khả năng tùy chỉnh các tham số điều khiển giúp cho mô hình có thể tạo sinh đầu ra đa dạng. Mô hình tiền huấn luyện đã học trên số lượng ảnh đủ lớn, nên tri thức về màu sắc của các đối tượng tự nhiên hay nhân tạo gần như đã được kết xuất.

Việc tinh chỉnh mô hình trên các tập dữ liệu chuyên biệt giúp cho các mô hình chuyên biệt tập trung hơn vào một miền dữ liệu cụ thể, tăng cường chất lượng ảnh được tô màu. Mô hình cũng có khả năng hoạt động trong hai chế độ chính: tô màu tự động hoàn toàn, và tô màu có điều kiện tuân theo hướng dẫn bằng lời nhắc văn bản.

Về mặt dữ liệu, nhóm đã thu thập, xử lý và chuẩn bị các tập dữ liệu phục vụ cho huấn luyện các mô hình tô màu chuyên biệt, bao gồm dữ liệu khuôn mặt, nội thất và thời trang.

5.2 Bàn luận

Mô hình tô màu do nhóm đề xuất đã đạt được kết quả khả quan khi tiến hành đánh giá thực nghiệm trên nhiều tập dữ liệu khác nhau. Tuy nhiên, mô hình cũng vẫn còn gặp một số thách thức như:

- Trong những trường hợp mô tả mơ hồ, thiếu ngữ cảnh kết quả vẫn có thể không đúng như mong đợi.
- Khả năng hiểu ngôn ngữ phụ thuộc mạnh vào chất lượng bộ mã hóa văn bản.
- Khi mô tả văn bản xung đột với đặc trưng hình ảnh, mô hình có thể bị lúng túng giữa việc tin ảnh hay tin văn bản.
- Các tập dữ liệu trên các miền chuyên biệt được chuẩn bị chưa quá tốt, dẫn đến kết quả đánh giá của các mô hình chuyên dụng chưa đạt được mong muốn thực tế.

Quá trình thêm điều kiện vào mô hình thông qua các bộ mã hóa đặc trưng và các cơ chế như chú ý chéo góp phần rất quan trọng vào việc cải thiện hiệu suất của mô hình huấn luyện. Nghiên cứu có thể được mở rộng bằng cách thay thế hoặc phát triển các thành phần này để có thể tăng khả năng tô màu của mô hình cũng như tích hợp thêm các điều khiển khác.

Kiến trúc kết hợp điều kiện vào các mô hình khuếch tán cho phép các sự thay đổi linh hoạt trong mô hình. Các hướng nghiên cứu tiếp theo có thể mở rộng sang việc tích hợp thêm các điều kiện không gian khác nhằm tạo ra các mô hình mới trong các lĩnh vực liên quan.

Phụ lục A

Phụ lục

A.1 Bảng đối chiếu thuật ngữ

Bảng A.1 cung cấp bảng đối chiếu các thuật ngữ Việt-Anh:

Bảng A.1: Phụ lục đối chiếu Việt Anh

Tiếng Việt	Tiếng Anh
Trí tuệ nhân tạo	Artificial Intelligence
Học sâu	Deep Learning
Mạng nơ-ron tích chập	Convolutional Neural Network
Mạng nơ-ron	Neural Network
Bộ mã hóa	Encoder
Bộ giải mã	Decoder
Chú ý	Attention
Chú ý chéo	Cross-Attention
Bộ biến đổi	Transformer
Mô hình khuếch tán	Diffusion Model

A.2 Mã nguồn mẫu

Bạn có thể chèn mã nguồn vào phụ lục:

```
1 def hello_world():  
2     print("Hello, World!")
```

```
3     return True
4
5 if __name__ == "__main__":
6     hello_world()
```

Listing A.1: Ví dụ mã Python

A.3 Thông tin bổ sung

Phụ lục có thể chứa các thông tin bổ sung như:

- Dữ liệu thực nghiệm chi tiết
- Mã nguồn đầy đủ
- Các bảng kết quả bổ sung
- Tài liệu tham khảo bổ sung