

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - Nguyễn Đức Mạnh -
Lê Quang Vĩnh Quyền

KHẢO SÁT
NHỮNG KỸ THUẬT TƯƠNG TỰ TRONG
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, Ngày 21 tháng 1 năm 2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - 21120081

Nguyễn Đức Mạnh - 22120204

Lê Quang Vĩnh Quyền - 22120307

KHẢO SÁT
NHỮNG KỸ THUẬT TƯƠNG TỰ TRONG
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lê Hoàng Thái

ThS. Dương Thái Bảo

Tp. Hồ Chí Minh, Ngày 21 tháng 1 năm 2026

Lời cam đoan

Chúng tôi xin cam đoan rằng đây là công trình nghiên cứu của chính chúng tôi. Dữ liệu và kết quả nghiên cứu trình bày trong báo cáo khóa luận là trung thực và không trùng lặp với bất kỳ đề tài nào khác. Chúng tôi cam kết rằng toàn bộ nội dung của báo cáo này không sao chép hay đạo văn từ bất kỳ công trình nghiên cứu nào khác.

Trong suốt quá trình thực hiện khóa luận, chúng tôi luôn chấp hành đầy đủ các quy định về đạo đức nghiên cứu, đảm bảo trích dẫn đúng và đầy đủ tất cả các nguồn tài liệu tham khảo, đồng thời giữ vững tinh thần trung thực học thuật trong mọi khía cạnh của báo cáo.

Lời cảm ơn

Có cần không ?

Trước hết, chúng tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc đến PGS.TS. Lê Hoàng Thái và ThS. Dương Thái Bảo vì sự hướng dẫn tận tình, khích lệ và hỗ trợ quý báu, giúp chúng tôi có cơ hội khám phá các hướng nghiên cứu mới.

Trong suốt quá trình thực hiện đề tài, quý Thầy đã chia sẻ những kiến thức giá trị và đóng góp nhiều gợi ý sâu sắc, giúp chúng tôi định hướng được con đường nghiên cứu của riêng nhóm thông qua các buổi trao đổi từ những ngày đầu cho đến khi hoàn thành nghiên cứu.

Mục lục

Lời cảm ơn	ii
Mục lục	iii
Danh sách hình vẽ	v
Danh sách bảng	vi
Tóm tắt	vi
1 Phương pháp đề xuất	1
1.1 Tổng quan về mô hình	2
1.1.1 Quy trình chung	2
1.1.2 Mô-đun trích xuất chuyển động theo vùng có khả năng thích ứng - ARME	3
1.1.3 Mô-đun gộp không gian-thời gian có khả năng thích ứng - ASTP	7
1.1.4 Mô-đun tổng hợp đặc trưng theo thời gian ở mức khung hình - FTA	8
1.2 Thay thế kỹ thuật ARME thành P3D[1]	9
1.2.1 Nguyên lý	9
1.2.2 Độ phức tạp tính toán	11
1.2.3 Tổng tham số của mô hình	11
1.2.4 Chi phí huấn luyện	12

1.3 Thay thế Triplet Loss bằng Circle Loss	12
Tài liệu tham khảo	13
A Phụ lục	14
A.1 Bảng đối chiếu thuật ngữ	14
A.2 Mã nguồn mẫu	14
A.3 Thông tin bổ sung	15

Danh sách hình vẽ

1.1	Tổng quan về mô hình Học biểu diễn không gian phân cấp (HSTL).	2
1.2	Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.	5
1.3	Minh họa mô-đun FTA	9
1.4	Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.	10

Danh sách bảng

A.1	Phụ lục đối chiếu Việt Anh	14
-----	--------------------------------------	----

Tóm tắt

Phần quy định chung khi trình bày báo cáo:

- Tất cả biểu thức toán phải được đánh số.
- Tất cả hình vẽ, bảng biểu phải có chú thích, và đánh dấu để tham chiếu trong mục lục.
- Hạn chế tối đa việc dùng tiếng anh, kể cả các thuật ngữ chuyên môn, có gắng dịch sang tiếng việt với từ ngữ dễ hiểu. Trong trường hợp quá khó để phiên dịch, được phép dùng tiếng anh, nhưng phải bổ sung ở bảng A.1 trong phần **Phụ lục**.
- Các tài liệu đính kèm phải theo một chuẩn duy nhất, không tham khảo loạn xạ. Có nhiều cách để lấy định dạng chuẩn, cách đơn giản nhất là tìm bài báo đó trên trang **arxiv**, tìm dòng **export BibTeX citation**, sao chép định dạng đó vào file **references.bib**.

Viết theo mẫu bên dưới

Tô màu ảnh độ xám là quá trình ước lượng các giá trị màu RGB cho từng điểm trong ảnh độ xám, nhằm chuyển đổi chúng thành ảnh màu. Tô màu ảnh độ xám được chia thành hai nhóm lớn: tô màu tự động và tô màu bán tự động. Tuy nhiên, hầu hết các mô hình hiện tại chỉ tập trung vào một phương thức duy nhất, điều này hạn chế tính năng mà người dùng mong muốn.

Trong nghiên cứu này, nhóm giới thiệu một mô hình tô màu ảnh độ xám kết hợp cả hai phương thức tự động và bán tự động (dựa trên lời

nhắc văn bản) được phát triển dựa trên kiến trúc mô hình ControlNet. ControlNet là một kiến trúc mạng nơ-ron được thiết kế nhằm tích hợp các điều kiện điều khiển không gian vào các mô hình tạo sinh ảnh từ văn bản đã được huấn luyện trước.


Nhóm đã tiến hành huấn luyện mô hình trên bốn tập dữ liệu cho các mục đích khác nhau. Sau đó nhóm tiến hành thử nghiệm mô hình tô màu chính trên ba tập dữ liệu đánh giá khác nhau. Kết quả đánh giá cho thấy, mô hình của nhóm đã vượt qua hầu hết các phương pháp tô màu tiên tiến trước đó trên phương thức tô màu tự động về chỉ số Colorfulness. Cuối cùng, nhóm xây dựng thêm một giao diện đơn giản để người dùng có thể sử dụng và ứng dụng các mô hình vào các công việc có liên quan đến tô màu ảnh độ xám.

Chương 1

Phương pháp đề xuất

Mục này có cách viết đơn giản nhất là sẽ trình bày lại gần như đầy đủ các nội dung của phương pháp được chọn, nhưng những phần hạn chế sẽ được thay thế bằng các cải tiến do nhóm đề xuất. Cụ thể:

- Vẽ lại sơ đồ phương pháp đề xuất với các thành phần cải tiến được đề xuất.
- Đối với cải tiến khối **Conv3D**, báo cáo này không trình bày lại, mà trình bày thẳng về khối **Pseudo 3D**. Bên cạnh đó, bổ sung các so sánh lý thuyết giữa kỹ thuật đề xuất so với kỹ thuật gốc (khác biệt về nguyên lý, độ phức tạp thuật toán, chi phí huấn luyện, tổng tham số của mô hình lớn,...)
- Tương tự với **Circle Loss**.
- Tất cả các hình vẽ về các kỹ thuật hay phương pháp đề xuất, phải được chèn vào.
- Nội dung có sẵn khá lan man, không nên viết theo.



Hình 1.1: Tổng quan về mô hình Học biểu diễn không gian phân cấp (HSTL).

1.1 Tổng quan về mô hình

1.1.1 Quy trình chung

Hình 1.1 trình bày quy trình **HSTL**. Cho tập dữ liệu $\mathcal{D} = \{S_i\}_{i=1}^N$, gồm N chuỗi dáng đi, mỗi chuỗi $S_i \in \mathbb{R}^{C \times T \times H \times W}$ được biểu diễn bằng tensor 4 chiều bao gồm C kênh, T khung hình, và kích thước $H \times W$. Ở bước tiền xử lý, mỗi chuỗi được chia đều theo chiều ngang thành k phần rồi dùng thuật toán phân cụm phân cấp (cụ thể là DBSCAN) để tạo một thứ bậc chuyển động $\mathcal{P} = \{\mathcal{P}^{(l)}\}_{l=1}^L$, với L là số bậc trong phân cấp và $\mathcal{P}^{(l)} = \{\mathcal{P}_1^{(l)}, \dots, \mathcal{P}_{K_l}^{(l)}\}$ là tập các phân vùng ở mức l . Sự phân cấp là một thuộc tính có cấu trúc của các mẫu chuyển động dáng đi và dùng để hướng dẫn quy trình trích xuất đặc trưng dáng đi. **HSTL** xếp chồng các mô-đun theo cấu trúc phân cấp đó. Xét đầu vào S_{in} , nhánh chính của **HSTL** được biểu diễn như sau:

$$Y^M = \Gamma^{(L)} \circ \Psi^{(L-1)} \circ \dots \circ \Omega^{(2)} \circ \Psi^{(2)} \circ \Psi^{(1)}(S_{in}) \quad (1.1)$$

, trong đó $\Psi^{(l)}$, $\Gamma^{(l)}$, và $\Omega^{(l)}$ lần lượt là các mô-đun **ARME**, **ASTP** và **FTA** ở mức thứ l của $\mathcal{P}$. Vì **FTA** nén dữ liệu giữa các khung hình, nên chỉ được dùng một lần duy nhất tại mức l_Ω trong $\mathcal{P}$ (ví dụ, $l_\Omega = 2$ trong biểu thức 1.1) để tránh mất thông tin quá mức.

Các đặc trưng đáng đi ở các phân cấp khác được thu thập bằng cách truyền vào $\Gamma^{(l)}$ tương ứng:

- Đầu ra $Y^{(l)}$ của từng $\Psi^{(l)}$ ở mức $l \in \{1, 2, \dots, L-1\}$,
- và đầu ra $Y_\Omega^{(l_\Omega)}$ của $\Omega^{(l_\Omega)}$ ở mức l_Ω .

Đầu ra cuối cùng của quy trình **HSTL** được hình thành bằng cách ghép nối các đặc trưng, biểu diễn như sau:

$$Y = \left[Y^M, \Gamma^{(L-1)} \left(Y^{(L-1)} \right), \dots, \Gamma^{(l_\Omega)} \left(Y_\Omega^{(l_\Omega)} \right), \Gamma^{(2)} \left(Y^{(2)} \right), \Gamma^{(1)} \left(Y^{(1)} \right) \right], \quad (1.2)$$

Sau đó, Y được truyền qua các lớp kết nối đầy đủ (**FC**), trước khi tối ưu bằng tổ hợp hàm mất mát bộ ba $\mathcal{L}_{tri}$ và hàm mất mát entropy chéo $\mathcal{L}_{ce}$.

1.1.2 Mô-đun trích xuất chuyển động theo vùng có khả năng thích ứng - ARME

Mục tiêu của **ARME** là trích xuất các mẫu không gian-thời gian tương ứng với từng vùng cơ thể, và chúng phải độc lập với nhau. Dựa trên phân cấp $\mathcal{P}$, đầu vào X được phân thành K_l vùng tại mức l , ký hiệu là $\{X_j^{(l)}\}_{j=1}^{K_l}$, với $X_j^{(l)} \in \mathbb{R}^{C \times T \times H_j^{(l)} \times W}$ và $H_j^{(l)} = \frac{|P_j^{(l)}|}{k} H$ là chiều cao vùng j ở mức l . Mức l của **ARME**, $\Psi^{(l)}$ được biểu diễn như sau:

$$Y_\Psi^{(l)} = \Psi^{(l)}(X^{(l)}) = \left[f_1(X_1^{(l)}), f_2(X_2^{(l)}), \dots, f_{K_l}(X_{K_l}^{(l)}) \right], \quad (1.3)$$

trong đó, $f_j(\cdot)$ là phép tích chập giả 3 chiều (**gọi tắt là P3D**) (**không chia sẻ**) ??? ứng với vùng j . Đầu ra $Y_{\Psi}^{(l)} \in \mathbb{R}^{C^{(l)} \times T \times H \times W}$ của mức l có $C^{(l)}$ kênh, và giữ nguyên độ phân giải không gian và thời gian.

Kỹ thuật tích chập 3 chiều học đồng thời đặc trưng không gian và thời gian từ dữ liệu đoạn phim (tức các khung hình liên tiếp), tương tự với chuỗi các khung hình được dùng trong nghiên cứu này. Phương pháp này rất hiệu quả, nhưng lại có hạn chế rõ ràng, bao gồm chi phí tính toán cao và cần sử dụng bộ nhớ lớn. Nghiên cứu [1] đã giải quyết các hạn chế này bằng cách mô phỏng một bộ tích chập 3 chiều thông qua ghép một bộ tích chập 2 chiều với một bộ tích chập bổ trợ. Bộ tích chập 2 chiều học riêng biệt đặc trưng không gian, trong khi đó, bộ tích chập bổ trợ học đặc trưng thời gian đi kèm. Chúng ta sẽ phân tích kỹ thuật tích chập giả 3 chiều trên một số khía cạnh.

1. Nguyên lý

Xét một thao tác tích chập trên một vùng cơ thể thứ j tại cấp độ l . Giả sử đầu vào là tensor $X \in \mathbb{R}^{C_{in} \times T \times H \times W}$. Bộ lọc có kích thước không gian $k \times k$ và thời gian d .

P3D tách một nhân 3D kích thước $d \times k \times k$ thành hai nhân riêng biệt: một nhân không gian ($1 \times k \times k$) và một nhân thời gian ($d \times 1 \times 1$). Theo cơ chế như sau:

- Nhân không gian (S): Sử dụng bộ lọc kích thước $1 \times k \times k$, tương đương với mạng nơ-ron tích chập 2D để học các đặc trưng hình ảnh.
- Nhân thời gian (T): Sử dụng các bộ lọc $d \times 1 \times 1$ để xây dựng các kết nối thời gian giữa các bản đồ đặc trưng liền kề.

Ta thực hiện tuần tự, thay vì tính toán trực tiếp như trong ARME:


$$Y_{Spatial} = S(X_j) = W_S * X_j \quad (\text{Nhân } 1 \times k \times k)$$

$$Y_j = T(Y_{Spatial}) = W_T * Y_{Spatial} \quad (\text{Nhân } d \times 1 \times 1)$$

Trong đó $W_S \in \mathbb{R}^{C_{out} \times C_{in} \times 1 \times k \times k}$ và $W_T \in \mathbb{R}^{C_{out} \times C_{out} \times d \times 1 \times 1}$.

Trong nghiên cứu này, chúng tôi áp dụng cấu trúc của P3D-A. Cụ thể là thành phần thời gian (T) đi trực tiếp sau thành phần không gian (S) trên cùng một đường dẫn. Đầu ra của không gian là đầu vào của thời gian.

$$x_{t+1} = (I + T \cdot S) \cdot x_t = x_t + T(S(x_t))$$



P3D-A

Hình 1.2: Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.

2. Độ phức tạp tính toán

Ở mô-đun ARME trong HSTL, các đặc trưng chuyển động được trích xuất thông qua các bộ lọc tích chập 3D với kích thước $3 \times 3 \times 3$. Điều này đòi hỏi số lượng phép tính dấu phẩy động lớn do phải xử lý đồng thời thông tin không gian và thời gian. Trong khi đó, P3D cải tiến giải quyết vấn đề này bằng cách phân rã phép tích chập 3D thành hai thao tác tuần tự: tích chập không gian 2D ($1 \times k \times k$) và tích

chập thời gian 1D ($d \times 1 \times 1$). Về mặt lý thuyết, tỷ lệ giảm thiểu khối lượng tính toán R_{comp} được ước lượng như sau:

$$R_{comp} = \frac{\text{Chi phí}_{3D}}{\text{Chi phí}_{P3D}} \approx \frac{d \cdot k \cdot k}{(1 \cdot k \cdot k) + (d \cdot 1 \cdot 1)} = \frac{3 \cdot 3 \cdot 3}{9 + 3} = \frac{27}{12} \approx 2.25$$

Như vậy cho thấy P3D đã giúp giảm độ phức tạp tính toán khoảng 2.25 lần so với kỹ thuật ARME đã dùng trước đó, giúp tăng tốc độ suy luận của hệ thống.

3. Tổng tham số của mô hình

Một trong những thách thức lớn nhất của kiến trúc HSTL là sự gia tăng số lượng tham số do đặc thù sử dụng các bộ lọc tích chập độc lập cho từng vùng cơ thể. Do đó, việc tối ưu hóa cấu trúc nhân tại mô-đun này sẽ mang lại hiệu quả giảm tải trực tiếp cho toàn bộ mô hình.

Đối với mô-đun ARME, việc sử dụng tích chập 3D thuần túy đồng nghĩa với việc mỗi nhân phải học một khối trọng số kích thước $3 \times 3 \times 3$, tương đương với 27 tham số cho mỗi kênh đặc trưng trên mỗi vùng cơ thể. Khi số lượng vùng cơ thể K tăng lên để trích xuất đặc trưng chi tiết hơn, tổng lượng tham số của mô hình sẽ vô cùng lớn, dẫn đến nguy cơ quá khớp cao và kích thước tệp lưu trữ lớn.

Ngược lại, kiến trúc P3D đề xuất tiếp cận vấn đề bằng cách phân rã nhân 3D thành hai thành phần trực giao: một bộ lọc không gian kích thước $1 \times 3 \times 3$ và một bộ lọc thời gian kích thước $3 \times 1 \times 1$. Tổng số tham số cần thiết cho cấu trúc tách biệt này chỉ là $9 + 3 = 12$ tham số.

Như vậy, ta có thể thấy kiến trúc đề xuất giúp loại bỏ khoảng 55.6% lượng tham số dư thừa tại các lớp tích chập $((27 - 12)/27)$. Sự tinh giản này giúp HSTL trở nên gọn nhẹ hơn đáng kể, đồng thời đóng buộc mô hình phải học các đặc trưng cốt lõi hiệu quả hơn thay vì

ghi nhớ nhiều từ dữ liệu huấn luyện.

4. Chi phí huấn luyện

Mặc dù P3D tách biệt các thành phần không gian và thời gian, việc tích hợp các kết nối tắt trong khối P3D giúp quá trình lan truyền ngược đạo hàm diễn ra hiệu quả hơn so với mạng tích chập 3D thuần túy. Nhờ đó, mô hình đạt được khả năng hội tụ ổn định hơn, ngay cả khi độ sâu của mạng được gia tăng.

Nhờ số lượng tham số được giảm đáng kể, mô hình đề xuất tiêu thụ ít bộ nhớ đồ họa hơn trong quá trình lan truyền ngược. Điều này cho phép sử dụng kích thước lô huấn luyện lớn hơn trên cùng một cấu hình phần cứng. Trong các bài toán học đo lường, chẳng hạn như nhận dạng dáng đi, việc sử dụng kích thước lô lớn đóng vai trò then chốt, giúp mô hình học được các mẫu khó hiệu quả hơn, từ đó gián tiếp cải thiện độ chính xác.

1.1.3 Mô-đun gộp không gian-thời gian có khả năng thích ứng - ASTP

ASTP thực hiện ánh xạ đặc trưng phân cấp bằng cách áp dụng kỹ thuật gộp (**pooling**) không đều lên các vùng thu được từ $\mathcal{P}$. Với vùng j của mức l , $X_j^{(l)}$, mô-đun **ASTP** tại mức l , $\Gamma^{(l)}$, được biểu diễn như sau:

$$Y_{\Gamma,j}^{(l)} = \Gamma_j^{(l)}(X_j^{(l)}) = \text{GeM}_j \circ \text{FC} \circ \text{Max}(X_j^{(l)}), \quad (1.4)$$

trong đó, $\text{Max}(\cdot)$ là phép gộp dựa trên giá trị lớn nhất (max pooling) dọc theo trục thời gian, $\text{FC}(\cdot)$ là lớp kết nối đầy đủ, $\text{GeM}_j(\cdot)$ là phép gộp trung bình tổng quát (generalized mean pooling (GeM)) **radenovic2018fine** cho vùng j . Chuỗi phép ánh xạ của Γ_j như sau: $\Gamma_j : \mathbb{R}^{C \times T \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C \times 1 \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C^{(l)} \times 1 \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C^{(l)} \times 1 \times 1 \times 1}$. Nối các $Y_{\Gamma,j}^{(l)}$ theo thứ tự, thu được $Y_{\Gamma}^{(l)} = [Y_{\Gamma,1}^{(l)}, Y_{\Gamma,2}^{(l)}, \dots, Y_{\Gamma,K_l}^{(l)}]$, với $Y_{\Gamma}^{(l)} \in \mathbb{R}^{C^{(l)} \times 1 \times K_l \times 1}$ là đầu ra của

ASTP ở mức l .

1.1.4 Mô-đun tổng hợp đặc trưng theo thời gian ở mức khung hình - FTA

FTA nén các khung hình cục bộ để loại bỏ khung dư thừa bằng cách kết hợp đa tỉ lệ thời gian và chọn khung tại mức khung hình. Với vùng $X_j^{(l)}$, hai phép gộp theo thời gian với nhân $3 \times 1 \times 1$ và $5 \times 1 \times 1$ (với cùng độ trượt $3 \times 1 \times 1$) sinh ra $U_{j,1}^{(l)}$ và $U_{j,2}^{(l)}$, biểu diễn như sau:

$$\begin{aligned}\hat{U}_j^{(l)} &= U_{j,1}^{(l)} + U_{j,2}^{(l)} \\ &= \text{Max}_{3 \times 1 \times 1}^{3 \times 1 \times 1} \left(X_j^{(l)} \right) + \text{Max}_{5 \times 1 \times 1}^{3 \times 1 \times 1} \left(X_j^{(l)} \right),\end{aligned}\tag{1.5}$$

trong đó, $\text{Max}_{3 \times 1 \times 1}^{3 \times 1 \times 1}(\cdot)$ và $\text{Max}_{5 \times 1 \times 1}^{3 \times 1 \times 1}(\cdot)$ là phép gộp dựa trên giá trị lớn nhất. $\hat{U}_j^{(l)}$, $U_{j,1}^{(l)}$ và $U_{j,2}^{(l)}$ có cùng kích thước $(C, \frac{T}{3}, H_j^{(l)}, W)$.

Tiếp đó, **FTA** sinh trọng số lựa trong khung:


$$\begin{aligned}Z_{j,1}^{(l)} &= \text{FC}_{j,1}^{(l)} \left(\text{GAP} \left(\hat{U}_j^{(l)} \right) \right), \\ Z_{j,2}^{(l)} &= \text{FC}_{j,2}^{(l)} \left(\text{GAP} \left(\hat{U}_j^{(l)} \right) \right),\end{aligned}\tag{1.6}$$

trong đó, $\text{GAP}(\cdot)$ là phép gộp trung bình toàn cục dọc theo chiều không gian, $Z_{j,1}^{(l)}$ và $Z_{j,2}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times 1 \times 1}$. Trọng số được chuẩn hóa chéo trên 2 tỉ lệ, được biểu diễn như sau:

$$\mathcal{W}_{j,s,c,t}^{(l)} = \frac{e^{Z_{j,s,c,t}^{(l)}}}{e^{Z_{j,1,c,t}^{(l)}} + e^{Z_{j,2,c,t}^{(l)}}} \quad s \in \{1, 2\},\tag{1.7}$$

trong đó, $\mathcal{W}_{j,s,c,t}^{(l)} \in \mathbb{R}^{1 \times 1 \times 1 \times 1}$ là trọng số của kênh của khung hình t . Kết hợp biểu thức (1.5) và biểu thức (1.7), đầu ra vùng j , $Y_{\Omega,j}^{(l)} \in \mathbb{R}^{C^{(l)} \times \frac{T}{3} \times H_j^{(l)} \times W}$ ở mức l **FTA** được biểu diễn như sau:

$$Y_{\Omega,j}^{(l)} = \mathcal{W}_{j,1}^{(l)} \odot U_{j,1}^{(l)} + \mathcal{W}_{j,2}^{(l)} \odot U_{j,2}^{(l)},\tag{1.8}$$



Hình 1.3: Minh họa mô-đun **FTA**.

trong đó $\mathcal{W}_{j,1}^{(l)}, \mathcal{W}_{j,2}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times 1 \times 1}$ là 2 tensor trọng số được tính theo biểu thức (1.5), và $\odot$ là phép nhân trên từng phần tử. Kết quả của **FTA**, $Y_{\Omega}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times H \times W}$ được tạo bằng cách ghép nối K_l vùng của mức l , với $Y_{\Omega}^{(l)} = [Y_{\Omega,1}^{(l)}, Y_{\Omega,2}^{(l)}, \dots, Y_{\Omega,K_l}^{(l)}]$.

1.2 Thay thế kỹ thuật ARME thành P3D[1]

1.2.1 Nguyên lý

Xét một thao tác tích chập trên một vùng cơ thể thứ j tại cấp độ l . Giả sử đầu vào là tensor $X \in \mathbb{R}^{C_{in} \times T \times H \times W}$. Bộ lọc có kích thước không gian $k \times k$ và thời gian d .

P3D tách một nhân 3D kích thước $d \times k \times k$ thành hai nhân riêng biệt: một nhân không gian ($1 \times k \times k$) và một nhân thời gian ($d \times 1 \times 1$). Theo cơ chế như sau:

- Nhân không gian (S): Sử dụng bộ lọc kích thước $1 \times k \times k$, tương đương với mạng nơ-ron tích chập 2D để học các đặc trưng hình ảnh.
- Nhân thời gian (T): Sử dụng các bộ lọc $d \times 1 \times 1$ để xây dựng các kết nối thời gian giữa các bản đồ đặc trưng liền kề.

Ta thực hiện tuần tự, thay vì tính toán trực tiếp như trong ARME:


$$Y_{Spatial} = S(X_j) = W_S * X_j \quad (\text{Nhân } 1 \times k \times k)$$

$$Y_j = T(Y_{Spatial}) = W_T * Y_{Spatial} \quad (\text{Nhân } d \times 1 \times 1)$$

Trong đó $W_S \in \mathbb{R}^{C_{out} \times C_{in} \times 1 \times k \times k}$ và $W_T \in \mathbb{R}^{C_{out} \times C_{out} \times d \times 1 \times 1}$.

Trong nghiên cứu này, chúng tôi áp dụng cấu trúc của P3D-A. Cụ thể là thành phần thời gian (T) đi trực tiếp sau thành phần không gian (S) trên cùng một đường dẫn. Đầu ra của không gian là đầu vào của thời gian.

$$x_{t+1} = (I + T \cdot S) \cdot x_t = x_t + T(S(x_t))$$



P3D-A

Hình 1.4: Kiến trúc của khối P3D-A: Các bộ lọc không gian (S) và thời gian (T) được sắp xếp nối tiếp.

1.2.2 Độ phức tạp tính toán

Ở mô-đun ARME trong HSTL, các đặc trưng chuyển động được trích xuất thông qua các bộ lọc tích chập 3D với kích thước $3 \times 3 \times 3$. Điều này đòi hỏi số lượng phép tính dấu phẩy động lớn do phải xử lý đồng thời thông tin không gian và thời gian. Trong khi đó, P3D cải tiến giải quyết vấn đề này bằng cách phân rã phép tích chập 3D thành hai thao tác tuần tự: tích chập không gian 2D ($1 \times k \times k$) và tích chập thời gian 1D ($d \times 1 \times 1$). Về mặt lý thuyết, tỷ lệ giảm thiểu khối lượng tính toán R_{comp} được ước lượng như sau:

$$R_{comp} = \frac{\text{Chi phí}_{3D}}{\text{Chi phí}_{P3D}} \approx \frac{d \cdot k \cdot k}{(1 \cdot k \cdot k) + (d \cdot 1 \cdot 1)} = \frac{3 \cdot 3 \cdot 3}{9 + 3} = \frac{27}{12} \approx 2.25$$

Như vậy cho thấy P3D đã giúp giảm độ phức tạp tính toán khoảng 2.25 lần so với kỹ thuật ARME đã dùng trước đó, giúp tăng tốc độ suy luận của hệ thống.

1.2.3 Tổng tham số của mô hình

Một trong những thách thức lớn nhất của kiến trúc HSTL là sự gia tăng số lượng tham số do đặc thù sử dụng các bộ lọc tích chập độc lập cho từng vùng cơ thể. Do đó, việc tối ưu hóa cấu trúc nhân tại mô-đun này sẽ mang lại hiệu quả giảm tải trực tiếp cho toàn bộ mô hình.

Đối với mô-đun ARME, việc sử dụng tích chập 3D thuần túy đồng nghĩa với việc mỗi nhân phải học một khối trọng số kích thước $3 \times 3 \times 3$, tương đương với 27 tham số cho mỗi kênh đặc trưng trên mỗi vùng cơ thể. Khi số lượng vùng cơ thể K tăng lên để trích xuất đặc trưng chi tiết hơn, tổng lượng tham số của mô hình sẽ vô cùng lớn, dẫn đến nguy cơ quá khớp cao và kích thước tệp lưu trữ lớn.

Ngược lại, kiến trúc P3D đề xuất tiếp cận vấn đề bằng cách phân rã nhân 3D thành hai thành phần trực giao: một bộ lọc không gian kích thước

$1 \times 3 \times 3$ và một bộ lọc thời gian kích thước $3 \times 1 \times 1$. Tổng số tham số cần thiết cho cấu trúc tách biệt này chỉ là $9 + 3 = 12$ tham số.

Như vậy, ta có thể thấy kiến trúc đề xuất giúp loại bỏ khoảng 55.6% lượng tham số dư thừa tại các lớp tích chập $((27 - 12)/27)$. Sự tinh giản này giúp HSTL trở nên gọn nhẹ hơn đáng kể, đồng thời đóng buộc mô hình phải học các đặc trưng cốt lõi hiệu quả hơn thay vì ghi nhớ nhiều từ dữ liệu huấn luyện.

1.2.4 Chi phí huấn luyện

Mặc dù P3D tách biệt các thành phần không gian và thời gian, việc tích hợp các kết nối tắt trong khối P3D giúp quá trình lan truyền ngược đạo hàm diễn ra hiệu quả hơn so với mạng tích chập 3D thuần túy. Nhờ đó, mô hình đạt được khả năng hội tụ ổn định hơn, ngay cả khi độ sâu của mạng được gia tăng.

Nhờ số lượng tham số được giảm đáng kể, mô hình đề xuất tiêu thụ ít bộ nhớ đồ họa hơn trong quá trình lan truyền ngược. Điều này cho phép sử dụng kích thước lô huấn luyện lớn hơn trên cùng một cấu hình phần cứng. Trong các bài toán học đo lường, chẳng hạn như nhận dạng dáng đi, việc sử dụng kích thước lô lớn đóng vai trò then chốt, giúp mô hình học được các mẫu khó hiệu quả hơn, từ đó gián tiếp cải thiện độ chính xác.

1.3 Thay thế Triplet Loss bằng Circle Loss

Tài liệu tham khảo

Tiếng Anh

- [1] Qiu, Z., Yao, T., and Mei, T., *Learning spatio-temporal representation with pseudo-3d residual networks*, 2017. arXiv: 1711.10305 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/1711.10305>

Phụ lục A

Phụ lục

A.1 Bảng đối chiếu thuật ngữ

Bảng A.1 cung cấp bảng đối chiếu các thuật ngữ Việt-Anh:

Bảng A.1: Phụ lục đối chiếu Việt Anh

Tiếng Việt	Tiếng Anh
Trí tuệ nhân tạo	Artificial Intelligence
Học sâu	Deep Learning
Mạng nơ-ron tích chập	Convolutional Neural Network
Mạng nơ-ron	Neural Network
Bộ mã hóa	Encoder
Bộ giải mã	Decoder
Chú ý	Attention
Chú ý chéo	Cross-Attention
Bộ biến đổi	Transformer
Mô hình khuếch tán	Diffusion Model

A.2 Mã nguồn mẫu

Bạn có thể chèn mã nguồn vào phụ lục:

```
1 def hello_world():  
2     print("Hello , World!")
```

```
3     return True
4
5 if __name__ == "__main__":
6     hello_world()
```

Listing A.1: Ví dụ mã Python

A.3 Thông tin bổ sung

Phụ lục có thể chứa các thông tin bổ sung như:

- Dữ liệu thực nghiệm chi tiết
- Mã nguồn đầy đủ
- Các bảng kết quả bổ sung
- Tài liệu tham khảo bổ sung