

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - Nguyễn Đức Mạnh -
Lê Quang Vĩnh Quyền

KHẢO SÁT
NHỮNG KỸ THUẬT TƯƠNG TỰ TRONG
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, Ngày 23 tháng 1 năm 2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Phạm Thái Huy - 21120081

Nguyễn Đức Mạnh - 22120204

Lê Quang Vĩnh Quyền - 22120307

KHẢO SÁT
NHỮNG KỸ THUẬT TƯƠNG TỰ TRONG
NGHIÊN CỨU HỌC BIỂU DIỄN
KHÔNG GIAN-THỜI GIAN PHÂN CẤP
CHO BÀI TOÁN NHẬN DẠNG DÁNG ĐI

BÁO CÁO CUỐI KỲ - MÔN SINH TRẮC HỌC
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lê Hoàng Thái

ThS. Dương Thái Bảo

Tp. Hồ Chí Minh, Ngày 23 tháng 1 năm 2026

Lời cam đoan

Chúng tôi xin cam đoan rằng đây là công trình nghiên cứu của chính chúng tôi. Dữ liệu và kết quả nghiên cứu trình bày trong báo cáo khóa luận là trung thực và không trùng lặp với bất kỳ đề tài nào khác. Chúng tôi cam kết rằng toàn bộ nội dung của báo cáo này không sao chép hay đạo văn từ bất kỳ công trình nghiên cứu nào khác.

Trong suốt quá trình thực hiện đề tài, chúng tôi luôn chấp hành đầy đủ các quy định về đạo đức nghiên cứu, đảm bảo trích dẫn đúng và đầy đủ tất cả các nguồn tài liệu tham khảo, đồng thời giữ vững tinh thần trung thực học thuật trong mọi khía cạnh của báo cáo.

Lời cảm ơn

Có cần không ?

Trước hết, chúng tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc đến PGS.TS. Lê Hoàng Thái và ThS. Dương Thái Bảo vì sự hướng dẫn tận tình, khích lệ và hỗ trợ quý báu, giúp chúng tôi có cơ hội khám phá các hướng nghiên cứu mới.

Trong suốt quá trình thực hiện đề tài, quý Thầy đã chia sẻ những kiến thức giá trị và đóng góp nhiều gợi ý sâu sắc, giúp chúng tôi định hướng được con đường nghiên cứu của riêng nhóm thông qua các buổi trao đổi từ những ngày đầu cho đến khi hoàn thành nghiên cứu.

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Mục lục	iii
Danh sách hình vẽ	vi
Danh sách bảng	vii
Tóm tắt	vii
Tóm tắt	viii
1 Giới thiệu	1
1.1 Bối cảnh chung	1
1.2 Động lực	2
1.3 Phát biểu bài toán	3
1.4 Thách thức của bài toán	4
1.5 Đóng góp của khóa luận	5
1.6 Bố cục của khóa luận	6
2 Các công trình liên quan	7
2.1 Tổng quan và Phân loại phương pháp	7
2.2 Giai đoạn 2020 - 2021	8

2.2.1	GaitPart [7]	8
2.2.2	GaitGL [8]	9
2.2.3	GaitGraph [9]	9
2.2.4	End-to-End SMPL [10]	10
2.3	Giai đoạn 2022 - 2023	10
2.3.1	ReverseMask[11]	10
2.3.2	SMPLGait[5]	11
2.3.3	GaitEdge [12]	13
2.3.4	LidarGait[6]	14
2.3.5	Học biểu diễn không-thời gian phân cấp (HSTL)[4]	15
2.4	Giai đoạn 2024 - 2025	18
2.4.1	MambaGait	18
2.4.2	DAGait	18
2.4.3	MimicGait	19
2.4.4	LiCAF	19
3	Phương pháp đề xuất	20
3.1	Tổng quan về mô hình	21
3.1.1	Quy trình chung	21
3.1.2	Mô-đun trích xuất chuyển động theo vùng có khả năng thích ứng - ARME	22
3.1.3	Mô-đun gộp không gian-thời gian có khả năng thích ứng - ASTP	27
3.1.4	Mô-đun tổng hợp đặc trưng theo thời gian ở mức khung hình - FTA	28
3.1.5	Hàm mất mát	29
4	Thực nghiệm và Kết quả	38
4.1	Cài đặt thực nghiệm	38
4.1.1	Bộ dữ liệu CASIA-B	38
4.1.2	Chi tiết cài đặt	39
4.1.3	Chi tiết Kiến trúc Mô hình	39

4.2	So sánh với các phương pháp SOTA	40
4.3	Phân tích Thực nghiệm	40
4.3.1	Khảo sát và Phân tích Cấu trúc P3D	40
4.3.2	Khảo sát Hàm mất mát	42
4.3.3	Phân tích Hội tụ và Độ ổn định	42
4.3.4	Phân tích Chi tiết theo Góc nhìn	43
5	Kết luận và Hướng phát triển	47
5.1	Kết luận	47
5.2	Hạn chế	48
5.3	Hướng phát triển	48
	Tài liệu tham khảo	50
6	Danh mục thuật ngữ và chữ viết tắt	54

Danh sách hình vẽ

2.1	Khung kiến trúc của SMPLGait.	12
2.2	Khung kiến trúc gốc của HSTL[4].	16
3.1	Tổng quan về mô hình Học biểu diễn không gian phân cấp (HSTL).	21
3.2	Các biến thể của khối P3D: (a) P3D-A, (b) P3D-B, (c) P3D-C.	25
3.3	Minh họa mô-đun FTA	29
3.4	Phân tích độ lớn Gradient của Circle Loss (c) so với Triplet Loss (b).	30
4.1	Độ chính xác Rank-1 (NM) theo bước lặp.	43
4.2	Độ chính xác Rank-1 (BG) theo bước lặp.	43
4.3	Độ chính xác Rank-1 (CL) theo bước lặp.	44
4.4	Phân bố độ chính xác theo góc nhìn (NM).	44
4.5	Phân bố độ chính xác theo góc nhìn (BG).	45
4.6	Phân bố độ chính xác theo góc nhìn (CL) tại vòng lặp 100K.	46

Danh sách bảng

3.1	So sánh Triplet Loss và Circle Loss	35
4.1	Kiến trúc chi tiết của mô hình HSTL đề xuất (biến thể P3D) trên CASIA-B. Các khối Conv3d ở Level 2 và 3 được thay thế bằng P3D-A (S + T).	40
4.2	Độ chính xác Rank-1 (%) trên CASIA-B trong các điều kiện khác nhau (NM, BG, CL).	41
4.3	So sánh giữa Conv3D và P3D-A về số lượng tham số và chi phí tính toán.	41

Tóm tắt

Nhận dạng dáng đi là một trong những công nghệ sinh trắc học tiềm năng nhất hiện nay, cho phép xác định danh tính con người dựa trên thói quen di chuyển từ khoảng cách xa mà không cần sự hợp tác trực tiếp. Trong số các phương pháp tiên tiến, mô hình Học biểu diễn không-thời gian phân cấp đã đạt được độ chính xác ấn tượng trên các tập dữ liệu chuẩn. Tuy nhiên, việc sử dụng các khối tích chập 3 chiều khiến mô hình trở nên nặng nề về chi phí tính toán và số lượng tham số, gây khó khăn cho việc triển khai trên các thiết bị biên có tài nguyên hạn chế.

Trong khóa luận này, chúng tôi tập trung nghiên cứu tối ưu hóa kiến trúc HSTL nhằm đạt được sự cân bằng giữa hiệu suất và hiệu quả tính toán. Cụ thể, chúng tôi đề xuất hai hướng cải tiến chính:

1. **Tối ưu hóa kiến trúc mạng:** Thay thế các khối tích chập 3D nặng nề bằng kiến trúc P3D kết hợp (không gian - thời gian). Phương pháp này nhằm giảm thiểu sự dư thừa tham số và chi phí tính toán.
2. **Cải tiến hàm mất mát:** Khảo sát việc ứng dụng hàm mất mát Circle Loss thay thế cho Triplet Loss truyền thống để cải thiện khả năng phân biệt đặc trưng, đặc biệt với các mẫu khó.

Kết quả thực nghiệm trên bộ dữ liệu CASIA-B đã đem lại những kết luận quan trọng:

Thứ nhất, việc ứng dụng P3D là một chiến lược hiệu quả. Biến thể HSTL-P3D giúp **giảm khoảng 50% số lượng tham số** và **giảm 2.25 lần chi phí tính toán (FLOPs)** so với mô hình gốc, trong khi vẫn duy trì

độ chính xác nhận dạng tương đương ở hầu hết các điều kiện thử nghiệm (NM, BG). Điều này mở ra triển vọng lớn cho việc ứng dụng mô hình trên các thiết bị thực tế.

Thứ hai, đối với khảo sát về Circle Loss, kết quả thực nghiệm chưa đạt được kỳ vọng lý thuyết. Do những sai sót trong quá trình cài đặt thực nghiệm (cụ thể là sự kết hợp chưa phù hợp giữa Circle Loss và Cross-Entropy Loss), hiệu năng của các biến thể sử dụng hàm mất mát này bị suy giảm so với đường cơ sở. Chúng tôi đã phân tích thẳng thắn nguyên nhân của vấn đề này trong khóa luận và đề xuất phương án tái thực nghiệm trong tương lai.

Tổng hợp lại, khóa luận đóng góp một giải pháp tối ưu hóa hiệu quả (P3D) cho bài toán nhận dạng dáng đi, đồng thời cung cấp những phân tích thực tiễn sâu sắc về vai trò và cách triển khai các hàm mất mát trong mô hình học sâu.

Chương 1

Giới thiệu

1.1 Bối cảnh chung

Trong kỷ nguyên xây dựng các thành phố thông minh và xã hội số hóa hiện nay, hệ thống camera giám sát đã bùng nổ về số lượng và trở thành một phần không thể thiếu của hạ tầng an ninh công cộng. Với hàng triệu giờ chuỗi khung hình được ghi lại mỗi ngày, việc dựa vào sức người để theo dõi là bất khả thi, đặt ra nhu cầu cấp thiết về các hệ thống nhận diện tự động, thông minh để truy vết tội phạm và đảm bảo an toàn xã hội. Tuy nhiên, các phương pháp sinh trắc học truyền thống như vân tay hay mống mắt lại không thể áp dụng trong các tình huống giám sát thụ động từ xa.

Chính từ nhu cầu thực tiễn đó, Nhận dạng dáng đi đã nổi lên như một giải pháp tối ưu. Đây là kỹ thuật sinh trắc học hành vi nhằm xác định danh tính của cá nhân dựa trên dáng đi của con người. Bởi vì dáng đi được hình thành từ cấu trúc cơ xương độc nhất và thói quen vận động của mỗi người, tạo nên một dấu ấn riêng biệt có khả năng phân biệt cao. Ngay từ những năm 1970, các nghiên cứu tâm lý học nền tảng của Cutting và Kozlowski đã chứng minh rằng con người có khả năng nhận diện người quen chỉ thông qua sự chuyển động của các điểm sáng mô phỏng dáng đi mà không cần bất kỳ thông tin chi tiết nào về ngoại hình hay khuôn mặt[1].

1.2 Động lực

Động lực mạnh mẽ nhất thúc đẩy sự phát triển của nhận dạng dáng đi nằm ở khả năng nhận dạng tầm xa hoặc trong các điều kiện khó khăn [2], [3]. Trong khi các đặc điểm sinh trắc học vật lý như khuôn mặt, vân tay, mống mắt thường yêu cầu sự hợp tác của chủ thể, tiếp xúc gần, hoặc hình ảnh đầu vào có độ phân giải rất cao, thì dáng đi là đặc điểm sinh trắc học duy nhất có thể nhận diện được từ khoảng cách xa hàng chục mét và ngay cả trong điều kiện hình ảnh chất lượng thấp. Điều này cho phép hệ thống xác định danh tính đối tượng ngay cả khi họ quay lưng lại với camera, che mặt, hoặc bị khuất trong đám đông, biến nó thành công cụ lý tưởng cho các hệ thống giám sát thông minh mà không cần đối tượng phải tương tác trực tiếp với thiết bị.

Bên cạnh lợi thế về khoảng cách, tính chất khó ngụy trang và khả năng thu thập thụ động cũng là những yếu tố then chốt tạo nên sức hấp dẫn của lĩnh vực này. Dáng đi của một người được định hình bởi cấu trúc cơ xương và thói quen vận động ăn sâu qua thời gian, do đó rất khó để một cá nhân có thể thay đổi hoặc làm giả dáng đi của mình một cách tự nhiên trong thời gian dài, khác hẳn với việc dễ dàng đeo mặt nạ hay găng tay để che giấu khuôn mặt và vân tay. Hơn nữa, với sự bùng nổ của hạ tầng camera quan sát hiện nay, dữ liệu dáng đi có sẵn ở khắp mọi nơi và có thể được thu thập liên tục 24/7 một cách thụ động, tạo điều kiện thuận lợi to lớn cho các ứng dụng thực tế trong điều tra tội phạm, an ninh công cộng và y tế.

Tuy nhiên, rào cản lớn nhất hiện nay để triển khai các hệ thống này vào thực tế (ví dụ: trên các thiết bị biên hoặc camera thông minh) chính là chi phí tính toán [4]. Các mô hình hiện đại thường yêu cầu tài nguyên phần cứng lớn (GPU cao cấp) do sử dụng các kiến trúc mạng tích chập 3D phức tạp để xử lý chuỗi video. Điều này mâu thuẫn với yêu cầu triển khai trên các thiết bị biên có năng lực tính toán hạn chế tại các điểm giám sát thực tế.

Các mô hình hiện đại như HSTL [4] đạt độ chính xác rất cao nhờ sử dụng mạng tích chập 3 chiều. Mặc dù hiệu quả trong việc trích xuất đặc trưng không gian-thời gian, mạng tích chập 3D lại tiêu tốn tài nguyên tính toán khổng lồ và có số lượng tham số rất lớn. Điều này khiến việc triển khai chúng trên các hệ thống thời gian thực trở nên khó khăn.

Bên cạnh đó, các hàm mất mát truyền thống như Triplet Loss, dù phổ biến, lại gặp hạn chế trong việc tối ưu hóa các mẫu khó và hội tụ chậm. Việc tìm kiếm một hàm mục tiêu hiệu quả hơn để tăng cường khả năng phân biệt đặc trưng mà không làm tăng độ phức tạp mô hình là một hướng đi cần thiết.

Xuất phát từ những vấn đề trên, khảo sát này tập trung nghiên cứu việc tối ưu hóa kiến trúc HSTL bằng cách thay thế các khối tích chập 3D nặng nề bằng các khối tích chập giả 3D nhẹ hơn, đồng thời tích hợp hàm mất mát tròn để cải thiện hiệu suất huấn luyện và độ chính xác nhận dạng trên tập dữ liệu chuẩn CASIA-B.

1.3 Phát biểu bài toán

Bài toán nhận dạng dáng đi có thể được định nghĩa là một bài toán truy xuất người dựa trên dữ liệu video. Mục tiêu là khớp một chuỗi hình ảnh dáng đi đầu vào với một cơ sở dữ liệu các mẫu đã biết để xác định danh tính.

- **Đầu vào:** Chuỗi các khung hình dáng đi đã được căn chỉnh và tách nền từ tập dữ liệu CASIA-B.

$$\mathbf{S_P} = \{\mathbf{S_P}(1), \mathbf{S_P}(2), \dots, \mathbf{S_P}(M)\}$$

với M là số lượng khung hình trong chuỗi.

- **Đầu ra:** Danh tính của người trong video hoặc điểm số tương đồng cao nhất khi so khớp chuỗi đầu vào với các chuỗi mẫu đã lưu trong

cơ sở dữ liệu ($\mathbf{S}_G$).

Mỗi chuỗi con thăm dò $\mathbf{S}_{P_k}$ được so khớp với chuỗi thư viện $\mathbf{S}_G$ thông qua phép tương quan chéo:

$$\text{Corr}(\mathbf{S}_{P_k}, \mathbf{S}_G)(l) = \sum_{j=1}^{N_{Gait}} S(\mathbf{S}_P(k+j), \mathbf{S}_G(l+j)) \quad (1.1)$$

Tính toán độ tương đồng tổng thể giữa chuỗi thăm dò và chuỗi thư viện.

$$\text{Sim}(\mathbf{S}_P, \mathbf{S}_G) = \text{Median}_k \left(\max_l \text{Corr}(\mathbf{S}_{P_k}, \mathbf{S}_G)(l) \right) \quad (1.2)$$

1.4 Thách thức của bài toán

Mặc dù đã đạt được những bước tiến lớn, nhận dạng dáng đi vẫn phải đối mặt với nhiều thách thức:

- **Nhiều ngoại cảnh:** Sự thay đổi góc nhìn, điều kiện mang vác, và trang phục làm thay đổi đáng kể hình dạng hình học của đối tượng trên khung hình. Ví dụ, việc mặc áo khoác dài có thể che khuất hoàn toàn chuyển động của phần thân và chân, khiến độ chính xác của các mô hình hiện tại giảm mạnh (thường $< 90\%$ trên CASIA-B CL).
- **Cân bằng Hiệu năng - Chi phí:** Các mô hình chính xác cao thường quá nặng nề (hàng triệu tham số, FLOPs lớn), trong khi các mô hình nhẹ lại kém chính xác. Thách thức đặt ra là làm sao duy trì độ chính xác của HSTL trong khi cắt giảm đáng kể chi phí tính toán để phù hợp với các thiết bị nhúng như NVIDIA Jetson.
- **Vấn đề Đạo đức và Quyền riêng tư:** Việc thu thập dữ liệu dáng đi thụ động có thể xâm phạm quyền riêng tư của công dân [3] nếu không có cơ chế quản lý và bảo mật phù hợp. Ví dụ, việc nhận dạng

một người đi bộ trên phố mà không có sự đồng thuận của họ có thể dẫn đến việc giám sát lạm quyền. Thách thức nằm ở việc xây dựng các hệ thống nhận dạng minh bạch, ẩn danh hóa dữ liệu và đảm bảo tuân thủ các quy định về bảo vệ dữ liệu cá nhân như GDPR.

1.5 Đóng góp của khóa luận

Trong báo cáo này, mục tiêu chính là nghiên cứu và cải tiến mô hình HSTL để đạt được sự cân bằng tối ưu giữa độ chính xác và hiệu quả tính toán. Những đóng góp chính bao gồm:

Về mặt lý thuyết và phương pháp:

- **Tối ưu hóa kiến trúc mạng:** Đề xuất thay thế kiến trúc tích chập ba chiều bằng kiến trúc tích chập **giả 3D (P3D)** trong mô-đun trích xuất đặc trưng chuyển động dựa trên vùng thích ứng. Phương pháp này giúp phân rã quá trình học đặc trưng, giảm thiểu tham số và chi phí tính toán (FLOPs giảm 2.25 lần) mà vẫn giữ nguyên khả năng mô hình hóa không gian-thời gian.
- **Cải tiến hàm mất mát:** Tích hợp **hàm mất mát tròn** thay thế cho hàm mất mát bộ ba (tam phân). Hàm mất mát tròn với cơ chế trọng số tự điều chỉnh giúp mô hình tối ưu hóa tốt hơn trên các mẫu khó, đặc biệt hiệu quả trong điều kiện thay đổi trang phục, nơi sự biến đổi nội lớp là rất lớn.

Về mặt thực nghiệm:

- Thực hiện đánh giá toàn diện trên tập dữ liệu **CASIA-B** theo các điều kiện chuẩn (NM, BG, CL), đồng thời so sánh với các phương pháp SOTA khác.
- Cung cấp các phân tích so sánh chi tiết giữa mô hình gốc HSTL và các biến thể đề xuất (HSTL-P3D, HSTL-CircleLoss, HSTL-P3D-CircleLoss).

1.6 Bố cục của khóa luận

Báo cáo môn học bao gồm năm chương: Chương 1 trình bày bối cảnh, động lực và đóng góp của đề tài. Chương 2 khảo sát các công trình liên quan và vị trí của HSTL. Chương 3 trình bày quy trình HSTL, đồng thời phân tích các kỹ thuật thay thế đề xuất P3D và hàm mất mát tròn theo nhiều khía cạnh và sự kỳ vọng trong cải thiện chất lượng mô hình so với phiên bản gốc. Chương 4 trình bày chi tiết thực nghiệm và phân tích kết quả trên tập CASIA-B, đồng thời bàn luận về sự ảnh hưởng của các phương pháp đối với quy trình HSTL. Chương 5 tổng kết và đề xuất hướng phát triển.

Chương 2

Các công trình liên quan

2.1 Tổng quan và Phân loại phương pháp

Trước khi đi vào chi tiết các nghiên cứu theo thời gian, chúng ta có thể phân loại các kỹ thuật nhận dạng dáng đi thành ba nhóm chính dựa trên biểu diễn dữ liệu đầu vào. Dựa trên các bài khảo sát toàn diện gần đây [2], [3], chúng tôi hệ thống hóa các hướng tiếp cận như sau:

1. Phương pháp dựa trên Ngoại hình:

- **Ý tưởng:** Sử dụng trực tiếp dữ liệu hình ảnh (RGB, bóng dáng, GEI) để trích xuất đặc trưng mà không cần mô hình hóa cấu trúc cơ thể [3].
- **Điểm mạnh:** Dễ thu thập dữ liệu, hoạt động hiệu quả với video độ phân giải thấp, không cần bước ước lượng tư thế tốn kém. Hiện tại là nhóm phương pháp có độ chính xác cao nhất trên các tập dữ liệu chuẩn.
- **Điểm yếu:** Nhạy cảm với các yếu tố ngoại cảnh như thay đổi trang phục, vật mang theo, và góc nhìn. Phụ thuộc lớn vào chất lượng thuật toán tách nền.

2. Phương pháp dựa trên Mô hình:

- **Ý tưởng:** Khôi phục cấu trúc cơ thể (khung xương 2D/3D, mô hình SMPL[5]) từ video và sử dụng các tham số này để nhận dạng.
- **Điểm mạnh:** Bất biến với thay đổi trang phục và màu sắc. Nắm bắt được động lực học của chuyển động khớp.
- **Điểm yếu:** Độ chính xác phụ thuộc hoàn toàn vào mô hình ước lượng tư thế. Thường thất bại khi hình ảnh mờ hoặc độ phân giải thấp (nơi khó bắt xương). Chi phí tính toán cao (đặc biệt với SMPL).

3. Phương pháp đa phương thức / 3D:

- **Ý tưởng:** Sử dụng các cảm biến khác ngoài camera thường như LiDAR, Camera chụp chiều sâu, hoặc kết hợp nhiều nguồn dữ liệu [6].
- **Điểm mạnh:** Hoạt động tốt trong điều kiện thiếu sáng hoặc ban đêm (nhờ LiDAR). Cung cấp thông tin hình học chính xác.
- **Điểm yếu:** Yêu cầu phần cứng chuyên dụng, đắt tiền, khó triển khai đại trà.

2.2 Giai đoạn 2020 - 2021

2.2.1 GaitPart [7]

- **Ý tưởng cốt lõi:** Mô hình hóa các phần cơ thể theo thời gian. Tác giả giới thiệu lớp *Focal Convolution*, chia bản đồ đặc trưng thành các phần ngang và thực hiện tích chập riêng biệt trên từng phần để nắm bắt chi tiết cục bộ tốt hơn so với các đặc trưng toàn cục.
- **Điểm mạnh:** Mô hình rất hiệu quả trong việc trích xuất các đặc trưng chi tiết của từng bộ phận cơ thể, đạt hiệu suất cao trên các

tập dữ liệu trong phòng thí nghiệm (ví dụ: CASIA-B).

- **Điểm yếu:** Cơ chế chia cửa sổ cố định của lớp Focal Convolution rất nhạy cảm với nhiễu. Trên các tập dữ liệu thực tế như Gait3D, chất lượng phân đoạn kém khiến lớp này hoạt động không hiệu quả. Thực tế, việc thay thế bằng các lớp tích chập thông thường giúp tăng độ chính xác Rank-1 lên đáng kể (+7.0%) trên Gait3D.

2.2.2 GaitGL [8]

- **Ý tưởng cốt lõi:** Kết hợp biểu diễn Toàn cục và Cục bộ. Nhận thấy đặc trưng toàn cục thường bỏ qua chi tiết, còn đặc trưng cục bộ thiếu liên kết ngữ cảnh, GaitGL sử dụng hai nhánh song song. Nhánh cục bộ sử dụng tích chập 3D để trích xuất thông tin vùng.
- **Điểm mạnh:** Đạt kết quả rất cao trên các chuẩn đánh giá trong nhà (như CASIA-B, OU-MVLP) nhờ khả năng tổng hợp thông tin đa dạng.
- **Điểm yếu:** Tương tự GaitPart, thiết kế nhánh cục bộ phức tạp không mang lại lợi ích trên dữ liệu thực tế. Các thử nghiệm cho thấy việc loại bỏ hoàn toàn nhánh cục bộ giúp cải thiện hoặc giữ nguyên hiệu suất trên Gait3D, chứng tỏ mô hình này chưa đủ mạnh mẽ trước các yếu tố nhiễu môi trường.

2.2.3 GaitGraph [9]

- **Ý tưởng cốt lõi:** Sử dụng Mạng nơ-ron đồ thị để xử lý dữ liệu khung xương 2D. Các khớp xương được coi là nút và xương là cạnh trong đồ thị để học mô hình chuyển động.
- **Điểm mạnh:** Mô hình gọn nhẹ và về lý thuyết có khả năng kháng lại sự thay đổi trang phục tốt hơn do không sử dụng thông tin thị

giác về quần áo/màu sắc.

- **Điểm yếu:** Do loại bỏ hoàn toàn thông tin hình dáng cơ thể, hiệu suất nhận diện thấp hơn đáng kể so với các phương pháp dựa trên ảnh bóng. Ví dụ, trên tập Gait3D, độ chính xác của GaitGraph thấp hơn rất nhiều so với các phương pháp tiêu chuẩn.

2.2.4 End-to-End SMPL [10]

- **Ý tưởng cốt lõi:** Tinh chỉnh mạng khôi phục dáng người trong dữ liệu lưới, để trích xuất đặc trưng dáng đi từ mô hình 3D SMPL theo một quy trình toàn vẹn.
- **Điểm mạnh:** Tận dụng được các kiến thức tiên nghiệm về cấu trúc 3D của cơ thể người.
- **Điểm yếu:** Việc ước tính chính xác mô hình SMPL từ một camera đơn trong điều kiện tự nhiên là rất khó khăn. Hơn nữa, vector đặc trưng của SMPL thường quá thừa, không đủ để mô tả các đặc điểm cá nhân chi tiết cần thiết cho nhận diện danh tính chính xác.

2.3 Giai đoạn 2022 - 2023

2.3.1 ReverseMask[11]

Các phương pháp phổ biến trước thường chia cơ thể người thành các phần nhỏ theo chiều ngang. Tuy nhiên, cách chia cứng nhắc này làm mất liên kết thông tin tại các đường ranh giới giữa các phần.

Dữ liệu dáng đi thường ít và hình ảnh dáng đi chứa ít thông tin. Các mạng nơ-ron sâu dễ bị ghi nhớ quá mức các đặc trưng cục bộ nổi trội như phần đầu hoặc chân mà bỏ qua cấu trúc tổng thể, dẫn đến khả năng tổng quát hóa kém.

Ý tưởng của ReverseMask: Sử dụng cơ chế điều chuẩn dựa trên mặt nạ để tiêm nhiễu vào bản đồ đặc trưng. Thay vì chỉ xóa bỏ đặc trưng, phương pháp này tạo ra nhiễu bằng cách vừa xóa vừa thay đổi tỷ lệ đặc trưng, buộc mô hình phải học cả các chi tiết tinh tế và cấu trúc tổng thể.

Điểm mạnh:

- Đạt hiệu suất vượt trội trên các bộ dữ liệu chuẩn CASIA-B, OU-MVLP, đặc biệt trong điều kiện thay đổi trang phục, nhờ khắc phục triệt để sự gián đoạn thông tin tại vùng biên của các mô hình chia phần truyền thống.
- Thông qua kiến trúc Inception-like ba nhánh, mô hình vừa học được chi tiết tinh tế vừa nắm bắt cấu trúc tổng thể, giúp giảm thiểu hiện tượng quá khớp và tăng cường khả năng tổng quát hóa.
- Có tính linh hoạt cao, dễ dàng tích hợp để cải thiện các mạng có sẵn và giúp quá trình huấn luyện ổn định hơn

Hạn chế:


- Việc triển khai khối Inception-like với ba nhánh song song, đồng nghĩa với việc gia tăng số lượng tham số và khối lượng tính toán trong quá trình huấn luyện và suy diễn.
- Hiệu quả của mô hình phụ thuộc vào các tham số như p (tỷ lệ diện tích mặt nạ) và các hệ số nhiễu α, β .
- Chỉ hoạt động tốt với ảnh dạng bóng, ít thông tin. Đối với các loại dữ liệu khác như ảnh RGB giàu thông tin, thì phương pháp này cần điều chỉnh hoặc không hiệu quả bằng.

2.3.2 SMPLGait[5]

Các phương pháp cũ chủ yếu dựa trên dữ liệu 2D như hình dáng, hình bóng hoặc khung xương 2D. Tuy nhiên, trong môi trường thực tế, việc

chiều cơ thể người 3D lên mặt phẳng 2D sẽ làm mất đi nhiều thông tin quan trọng như góc nhìn, hình dạng và động lực học

Ý tưởng của SMPLGait: Sử dụng biểu diễn 3D dày đặc thông qua mô hình SMPL để khôi phục thông tin về hình dạng và góc nhìn trong không gian 3D. Kết hợp thông tin này để chuẩn hóa các đặc trưng bề ngoài từ các góc nhìn khác nhau về một không gian đặc trưng thống nhất, giúp nhận diện chính xác hơn bất kể góc quay camera.



Hình 2.1: Khung kiến trúc của SMPLGait.

Điểm mạnh:

- Nhờ vào các tham số góc nhìn 3D từ mô hình SMPL, SMPLGait có thể chuẩn hóa định hướng của cơ thể người trong các tình huống khớp nối đa góc nhìn.
- SMPLGait vượt trội hơn hẳn các phương pháp 2D SOTA như GaitSet, GaitPart trên tập dữ liệu Gait3D đầy thách thức. Khả năng xử lý tốt các trường hợp bị che khuất và góc nhìn cực đoan cũng cao hơn nhờ thông tin hình học từ lưới 3D.

Hạn chế:

- Mô hình hiện tại chủ yếu tập trung vào đặc trưng không gian. Các thông tin về vận động theo thời gian chưa được khai thác triệt để, mặc dù đây là yếu tố quan trọng trong nhận dạng dáng đi.

- Hiệu quả của SMPLGait phụ thuộc nhiều vào mô hình khôi phục 3D. Nếu việc ước lượng tham số SMPL từ ảnh 2D bị sai do ảnh mờ, quá tối, hiệu suất nhận dạng sẽ giảm.
- Độ phức tạp tính toán lớn do phải chạy thêm một mô hình khôi phục 3D song song với mạng nhận dạng.

2.3.3 GaitEdge [12]

Các phương pháp học đầu-cuối trước đây thường trích xuất đặc trưng trực tiếp từ ảnh RGB hoặc thông qua các mặt nạ phân đoạn dạng số thực. Mặc dù các phương pháp này đạt hiệu quả tốt trong cùng một miền dữ liệu, nhưng trên thực tế mô hình có xu hướng ghi nhớ quá mức các đặc trưng không liên quan trực tiếp đến dáng đi, chẳng hạn như màu sắc trang phục hoặc họa tiết bề mặt, thay vì học các đặc trưng động học của dáng đi. Điều này dẫn đến sự suy giảm đáng kể hiệu năng khi đánh giá trên các tập dữ liệu khác miền.

Ý tưởng của GaitEdge: Phương pháp đề xuất tổng hợp một dạng bóng dáng nhân tạo, trong đó phần biên của cơ thể được biểu diễn dưới dạng giá trị số thực có thể huấn luyện nhằm bảo toàn thông tin hình dáng chi tiết, trong khi phần bên trong và vùng nền được ràng buộc về dạng nhị phân hoặc bị loại bỏ để hạn chế các nhiễu liên quan đến màu sắc và kết cấu bề mặt.

Điểm mạnh:

- GaitEdge đạt hiệu suất cao nhất trong các thí nghiệm đánh giá chéo giữa các tập dữ liệu khác nhau (ví dụ từ CASIA-B sang TTG-200), nhờ khả năng loại bỏ hiệu quả các nhiễu RGB vốn không ổn định giữa các môi trường
- Bằng cách giới hạn quá trình huấn luyện chủ yếu tại vùng biên của bóng dáng, mô hình được buộc phải tập trung vào các đặc trưng

dáng đi tinh vi, thay vì phụ thuộc vào các đặc trưng ngoại hình thô như màu sắc trang phục hoặc vật mang theo.

- Mô-đun GaitAlign giúp hệ thống duy trì hoạt động ổn định trong các điều kiện thực tế, nơi việc phát hiện người không hoàn hảo, qua đó cải thiện đáng kể độ chính xác trung bình.

Hạn chế:

- Trong huấn luyện và kiểm thử trên cùng một tập dữ liệu, GaitEdge có độ chính xác thấp hơn khoảng 2% so với các mô hình học đầu-cuối thuần túy, do việc loại bỏ một phần thông tin nội tại của bóng dáng làm suy giảm một số đặc trưng hữu ích trong cùng điều kiện môi trường.
- Hiệu suất tổng thể của phương pháp vẫn phụ thuộc vào chất lượng của mạng phân đoạn ban đầu, vốn chịu trách nhiệm cung cấp hình dáng ban đầu của đối tượng.
- Khả năng tổng quát hóa khác miền nhạy cảm với kích thước vùng biên được sử dụng, trong đó việc mở rộng vùng cạnh quá mức có thể dẫn đến suy giảm hiệu suất.

2.3.4 LidarGait[6]

Các phương pháp nhận diện dáng đi truyền thống thường dựa vào hình ảnh RGB hoặc bóng đen 2D. Tuy nhiên, cách tiếp cận này gặp khó khăn lớn trong môi trường thực tế do thiếu thông tin cấu trúc 3D của cơ thể người và dễ bị nhiễu bởi ánh sáng yếu, quần áo tiếp màu nền, hoặc nền phức tạp.

Ý tưởng của LidarGait: Thay vì trích xuất đặc trưng trực tiếp từ tập điểm thưa thớt như các mạng PointNet thường làm cho bài toán phân loại vật thể, LidarGait chiếu đám mây điểm 3D thành các bản đồ độ sâu dưới dạng hình ảnh 2D. Sau đó, phương pháp này tận dụng các kiến trúc

CNN tiêu chuẩn dành cho biểu diễn không gian hai chiều để trích xuất đặc trưng đáng đi.

Điểm mạnh:

- LidarGait vượt trội hơn camera RGB trong môi trường ngoài trời, đặc biệt là vào ban đêm hoặc điều kiện ánh sáng yếu, nơi mà các thuật toán phân đoạn hình ảnh thường thất bại.
- Không bị ảnh hưởng bởi việc thay đổi quần áo hoặc màu sắc quần áo trùng với phong nền, vì LidarGait thu thập dữ liệu hình học chứ không phải màu sắc.
- LidarGait duy trì hiệu suất nhận dạng rất ổn định ngay cả khi góc nhìn thay đổi mạnh, nhờ vào việc giữ được cấu trúc 3D thực của cơ thể người.

Hạn chế:


- LidarGait gặp khó khăn khi đối tượng cầm ô, vì ô thường được giữ lại trong đám mây điểm và gây nhiễu cho việc tính toán cấu trúc cơ thể, trong khi các thuật toán camera thường xóa bỏ phần này trong quá trình phân đoạn.
- Hiện tại LidarGait chủ yếu chỉ sử dụng một loại dữ liệu đầu vào là đám mây điểm 3D.
- Mật độ của đám mây điểm phụ thuộc vào khoảng cách của đối tượng đến cảm biến, điều này vẫn có tác động nhất định đến hiệu suất nhận dạng.

2.3.5 Học biểu diễn không-thời gian phân cấp (HSTL)[4]

Các phương pháp nhận diện dáng đi hiện tại thường chia cắt hình ảnh cơ thể thành các phần cố định chẳng hạn như cắt ngang thành 8 hoặc 16 phần,... để trích xuất đặc trưng. Tuy nhiên, cách làm này bỏ qua mối quan

hệ phân cấp tự nhiên của cơ thể người khi chuyển động. Ví dụ: chuyển động của bàn chân và cẳng chân có liên quan mật thiết với nhau, và chúng lại là một phần của chuyển động thân dưới.

Ý tưởng của HSTL: Thay vì xem xét các bộ phận cơ thể một cách rời rạc, HSTL học các đặc trưng đáng đi theo cấu trúc phân cấp từ thô đến tinh. Cụ thể, mô hình khai thác mối quan hệ phụ thuộc giữa các bộ phận cơ thể như đầu, thân, chân và tay ở nhiều mức độ khác nhau, từ biểu diễn toàn bộ cơ thể cho đến các vùng chi tiết cục bộ.



Hình 2.2: Khung kiến trúc gốc của HSTL[4].

Trong hình 2.2 chính là khung kiến trúc của HSTL. Phương pháp này chủ yếu bao gồm ba mô-đun: ARME (bộ trích xuất chuyển động dựa trên vùng thích ứng), ASTP (gộp không gian-thời gian thích ứng) và FTA (tổng hợp theo thời gian ở mức khung hình). Trong giai đoạn tiền xử lý, một cấu trúc phân cấp của đáng đi được xây dựng nhằm định hướng thiết kế kiến trúc của HSTL. Khung mô hình sử dụng nhiều ARME để trích xuất đặc trưng đáng đi từ toàn bộ cơ thể đến các vùng riêng lẻ. Mô-đun ASTP thực hiện ánh xạ đặc trưng phân cấp cho đầu ra của từng mức ARME. Mô-đun FTA nén các đoạn cục bộ của mỗi chuỗi đáng đi nhằm giảm số lượng khung hình dư thừa. Các ký hiệu T, H và W lần lượt biểu thị các chiều của bản

đồ đặc trưng. Ký hiệu © biểu thị phép nối.

Điểm mạnh:

- HSTL đạt kết quả tốt nhất trên các bộ dữ liệu quy mô lớn như CASIA-B, OUMVLP, GREW và Gait3D. Phương pháp này đặc biệt hiệu quả trong các điều kiện thách thức, chẳng hạn như thay đổi trang phục và mang vác. Ngoài ra, HSTL vẫn duy trì hiệu suất ổn định trong môi trường thực tế, nơi tồn tại nhiều nhiễu do sai lệch căn chỉnh cơ thể và sự xuất hiện của vật cản.
- So với các phương pháp sử dụng mạng tích chập 3D có độ phức tạp cao như GaitGL và 3D Local, HSTL đạt được sự cân bằng tốt hơn giữa độ chính xác và chi phí tính toán. Kiến trúc phân cấp của HSTL giúp hạn chế các phép tích chập 3D dư thừa, từ đó giảm đáng kể độ phức tạp tính toán.
- Mô-đun FTA giúp mô hình thích ứng tốt với sự thay đổi về tốc độ đi và sự dư thừa khung hình. Module ARME cho phép học các đặc trưng chuyển động riêng biệt cho từng vùng cơ thể thay vì gộp chung.
- Cải thiện đáng kể độ chính xác nhận dạng đối với trẻ em (nhóm đối tượng thường có dữ liệu ít hơn người lớn).

Hạn chế:

- Mặc dù đã được tối ưu so với các phương pháp trước đó, ARME vẫn dựa trên các phép tích chập 3D. Do phải đồng thời mô hình hóa cả không gian và thời gian, các toán tử này vẫn đòi hỏi chi phí tính toán quá lớn so với các mạng tích chập 2D.
- Là một phương pháp dựa trên ngoại hình và sử dụng bóng dáng làm đầu vào, mô hình vẫn chịu ảnh hưởng khi quá trình phân đoạn ban đầu không chính xác, đặc biệt trong các điều kiện môi trường phức tạp.

2.4 Giai đoạn 2024 - 2025

Giai đoạn này đánh dấu sự xuất hiện của các kiến trúc tính toán mới thay thế cho CNN/Transformer truyền thống và các kỹ thuật căn chỉnh dữ liệu tinh vi hơn.

2.4.1 MambaGait

- **Ý tưởng cốt lõi:** MambaGait [13] là phương pháp đầu tiên ứng dụng mô hình không gian trạng thái vào nhận dạng dáng đi. Thay vì dùng Attention (chi phí bậc hai) hay RNN (khó huấn luyện), MambaGait sử dụng khối *TWSM* kết hợp với đặc trưng không gian tường minh.
- **Điểm mạnh:** Khả năng mô hình hóa sự phụ thuộc thời gian dài tốt hơn CNN và hiệu quả hơn Transformer (chi phí tính toán tuyến tính $O(N)$ theo độ dài chuỗi). Đạt kết quả rất cạnh tranh với tốc độ suy diễn nhanh.
- **Điểm yếu:** Là kiến trúc mới, sự ổn định và khả năng tối ưu hóa chưa được kiểm chứng rộng rãi như CNN. Việc tích hợp vào các hệ thống hiện có phức tạp hơn.

2.4.2 DAGait

- **Ý tưởng cốt lõi:** DAGait [14] tập trung giải quyết vấn đề "rác vào, rác ra" của dữ liệu đầu vào. Nó sử dụng thông tin khung xương để hướng dẫn căn chỉnh các hình ảnh bóng dáng đi một cách chính xác thông qua biến đổi affine, thay vì chỉ căn chỉnh trọng tâm đơn giản.
- **Điểm mạnh:** Cải thiện đáng kể chất lượng dữ liệu đầu vào cho các mô hình dựa trên Ngoại hình, giúp tăng độ chính xác mà không cần thay đổi kiến trúc mạng nhận dạng.

- **Điểm yếu:** Phụ thuộc vào độ chính xác của bộ phát hiện khung xương. Nếu ước lượng xương sai, việc căn chỉnh sẽ làm méo mó hình ảnh đáng đi nghiêm trọng hơn.

2.4.3 MimicGait

- **Ý tưởng cốt lõi:** Giải quyết bài toán che khuất bằng cơ chế chứng cất tri thức. MimicGait [15] huấn luyện một mạng "sinh viên" trên dữ liệu bị che khuất để bắt chước đặc trưng của mạng "giáo viên" (được huấn luyện trên dữ liệu sạch).
- **Điểm mạnh:** Phương pháp "Model Agnostic" - có thể áp dụng cho bất kỳ mạng nào (GaitSet[16], GaitGL[8], HSTL[4]) để tăng cường khả năng chống chịu che khuất mà không làm thay đổi kiến trúc gốc.
- **Điểm yếu:** Yêu cầu quy trình huấn luyện phức tạp hơn (cần cặp dữ liệu sạch/che khuất giả lập). Hiệu quả phụ thuộc vào mức độ tương đồng giữa che khuất giả lập và thực tế.


2.4.4 LiCAF

- **Ý tưởng cốt lõi:** Kết hợp dữ liệu đám mây điểm LiDAR với hình ảnh Camera RGB theo cơ chế không đối xứng [17]. LiDAR cung cấp hình học chính xác, Camera cung cấp ngữ nghĩa phong phú.
- **Điểm mạnh:** Hoạt động mạnh mẽ trong mọi điều kiện ánh sáng (kể cả ban đêm hoàn toàn nhờ LiDAR). Khắc phục điểm yếu của từng cảm biến riêng lẻ.
- **Điểm yếu:** Chi phí phần cứng cao và vấn đề đồng bộ hóa giữa hai cảm biến phức tạp, khó triển khai trên diện rộng.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan về mô hình



Hình 3.1: Tổng quan về mô hình Học biểu diễn không gian phân cấp (HSTL).

3.1.1 Quy trình chung

Hình 3.1 trình bày quy trình **HSTL**. Cho tập dữ liệu $\mathcal{D} = \{S_i\}_{i=1}^N$, gồm N chuỗi dáng đi, mỗi chuỗi $S_i \in \mathbb{R}^{C \times T \times H \times W}$ được biểu diễn bằng tensor 4 chiều bao gồm C kênh, T khung hình, và kích thước $H \times W$. Ở bước tiền xử lý, mỗi chuỗi được chia đều theo chiều ngang thành k phần rồi dùng thuật toán phân cụm phân cấp (cụ thể là DBSCAN) để tạo một thứ bậc chuyển động $\mathcal{P} = \{\mathcal{P}^{(l)}\}_{l=1}^L$, với L là số bậc trong phân cấp và $\mathcal{P}^{(l)} = \{\mathcal{P}_1^{(l)}, \dots, \mathcal{P}_{K_l}^{(l)}\}$ là tập các phân vùng ở mức l . Sự phân cấp là một thuộc tính có cấu trúc của các mẫu chuyển động dáng đi và dùng để hướng dẫn quy trình trích xuất đặc trưng dáng đi. **HSTL** xếp chồng các mô-đun theo cấu trúc phân cấp đó. Xét đầu vào S_{in} , nhánh chính của **HSTL** được biểu diễn như sau:

$$Y^M = \Gamma^{(L)} \circ \Psi^{(L-1)} \circ \dots \circ \Omega^{(2)} \circ \Psi^{(2)} \circ \Psi^{(1)}(S_{in}) \quad (3.1)$$

, trong đó $\Psi^{(l)}$, $\Gamma^{(l)}$, và $\Omega^{(l)}$ lần lượt là các mô-đun **ARME**, **ASTP** và **FTA** ở mức thứ l của $\mathcal{P}$. Vì **FTA** nén dữ liệu giữa các khung hình, nên chỉ được dùng một lần duy nhất tại mức l_Ω trong $\mathcal{P}$ (ví dụ, $l_\Omega = 2$ trong biểu thức 3.1) để tránh mất thông tin quá mức.

Các đặc trưng đáng đi ở các phân cấp khác được thu thập bằng cách truyền vào $\Gamma^{(l)}$ tương ứng:

- Đầu ra $Y^{(l)}$ của từng $\Psi^{(l)}$ ở mức $l \in \{1, 2, \dots, L-1\}$,
- và đầu ra $Y_\Omega^{(l_\Omega)}$ của $\Omega^{(l_\Omega)}$ ở mức l_Ω .

Đầu ra cuối cùng của quy trình **HSTL** được hình thành bằng cách ghép nối các đặc trưng, biểu diễn như sau:

$$Y = \left[Y^M, \Gamma^{(L-1)} \left(Y^{(L-1)} \right), \dots, \Gamma^{(l_\Omega)} \left(Y_\Omega^{(l_\Omega)} \right), \Gamma^{(2)} \left(Y^{(2)} \right), \Gamma^{(1)} \left(Y^{(1)} \right) \right], \quad (3.2)$$

Sau đó, Y được truyền qua các lớp kết nối đầy đủ (**FC**), trước khi tối ưu bằng tổ hợp hàm mất mát tròn $\mathcal{L}_{circle}$ và hàm mất mát entropy chéo $\mathcal{L}_{ce}$.

3.1.2 Mô-đun trích xuất chuyển động theo vùng có khả năng thích ứng - ARME

Mục tiêu của **ARME** là trích xuất các mẫu không gian-thời gian tương ứng với từng vùng cơ thể, và chúng phải độc lập với nhau. Dựa trên phân cấp $\mathcal{P}$, đầu vào X được phân thành K_l vùng tại mức l , ký hiệu là $\{X_j^{(l)}\}_{j=1}^{K_l}$, với $X_j^{(l)} \in \mathbb{R}^{C \times T \times H_j^{(l)} \times W}$ và $H_j^{(l)} = \frac{|P_j^{(l)}|}{k} H$ là chiều cao vùng j ở mức l . Mức l của **ARME**, $\Psi^{(l)}$ được biểu diễn như sau:

$$Y_\Psi^{(l)} = \Psi^{(l)}(X^{(l)}) = \left[f_1(X_1^{(l)}), f_2(X_2^{(l)}), \dots, f_{K_l}(X_{K_l}^{(l)}) \right], \quad (3.3)$$

trong đó, $f_j(\cdot)$ là phép tích chập giả 3 chiều (**gọi tắt là P3D**) ứng với vùng j . Điểm quan trọng cần lưu ý là các trọng số của f_j là **riêng biệt (không chia sẻ)** giữa các vùng. Điều này cho phép mô hình học được các đặc trưng chuyển động đặc thù của từng bộ phận cơ thể (ví dụ: chuyển động vùng tay khác hoàn toàn với bước chân), thay vì dùng chung một bộ lọc cho toàn bộ cơ thể.

Kĩ thuật tích chập 3 chiều học đồng thời đặc trưng không gian và thời gian từ dữ liệu đoạn phim (tức các khung hình liên tiếp). Phương pháp này rất hiệu quả, nhưng lại có hạn chế rõ ràng về chi phí tính toán cao $O(k^3)$ và kích thước mô hình lớn. Nghiên cứu [18] đã giải quyết vấn đề này bằng cách phân rã nhân 3D thành 2D (không gian) + 1D (thời gian). Chúng ta sẽ phân tích sâu hơn về nguyên lý và các biến thể của nó.

1. Nguyên lý hoạt động (Intuition)

Hãy tưởng tượng việc tích chập 3D thông thường giống như việc cố gắng ghi nhớ một đoạn video bằng cách nuốt trọn toàn bộ khối dữ liệu $Space \times Time$ cùng lúc. Việc này rất nặng nề ($O(k^3)$) và dễ gây quá tải (overfitting).

P3D tiếp cận vấn đề thông minh hơn: nó chia nhỏ quá trình này thành hai bước nhẹ nhàng, giống như cách mắt người xử lý:

- (a) **Bước 1 - Không gian (S):** "Nhìn ảnh". Dùng bộ lọc 2D ($1 \times k \times k$) để hiểu hình dáng của đối tượng trong từng khung hình.
- (b) **Bước 2 - Thời gian (T):** "Nhìn chuyển động". Dùng bộ lọc 1D ($k \times 1 \times 1$) để xâu chuỗi sự thay đổi của hình dáng đó giữa các khung hình.

Thay vì học một khối W_{Conv3D} khổng lồ, ta học hai mảnh nhỏ W_s và $W_{temporal}$.

$$W_{Conv3D} \approx W_s \times W_{temporal} \quad (3.4)$$

Cụ thể, quá trình xử lý cho vùng cơ thể j diễn ra tuần tự:

$$A_s = f_j^s \left(X_j^{(l)} \right) = W_s * X_j^{(l)} \quad (\text{Trích xuất hình dáng}) \quad (3.5)$$

$$A_t = f_j^t (A_s) = W_t * A_s \quad (\text{Trích xuất chuyển động}) \quad (3.6)$$

Trong đó $W_s \in \mathbb{R}^{C_{out} \times C_{in} \times 1 \times k_h \times k_w}$ và $W_t \in \mathbb{R}^{C_{out} \times C_{out} \times k_t \times 1 \times 1}$. Sự phân rã này giữ nguyên khả năng biểu diễn nhưng giảm tải đáng kể tính toán.

Các biến thể của mạng tích chập giả 3D:

Thay vì liệt kê máy móc các công thức, chúng ta có thể tư duy về cách kết hợp Không gian (S) và Thời gian (T) theo ba hướng tiếp cận tự nhiên sau, giống như cách con người nhận thức chuyển động:

- **P3D-A (Xếp chồng):** Đây là tư duy trực quan nhất: "*Nhìn thấy hình dáng trước, rồi mới thấy chuyển động*". Cấu trúc này xếp bộ lọc thời gian (T) ngay sau bộ lọc không gian (S). Dữ liệu đi qua S để trích xuất đặc trưng hình ảnh tĩnh, sau đó đi qua T để liên kết các đặc trưng này theo chuỗi thời gian.

$$x_{t+1} = x_t + T(S(x_t)) \quad (3.7)$$

Chúng tôi chọn cấu trúc này cho HSTL vì nó phù hợp tuyệt đối với bản chất dữ liệu dáng đi: sự thay đổi của hình dáng cơ thể theo thời gian chính là thông tin định danh.


- **P3D-B (Song song):** Tách biệt hoàn toàn việc xử lý. Một nhánh chuyên trách nhìn hình dáng (S), một nhánh chuyên trách nhìn chuyển động (T). Kết quả cuối cùng là tổng hợp của hai góc nhìn độc lập này.

$$x_{t+1} = x_t + S(x_t) + T(x_t) \quad (3.8)$$

- **P3D-C (Kết hợp):** Một sự dung hòa phức tạp hơn. Vẫn giữ tư duy "hình dáng trước, chuyển động sau" của P3D-A, nhưng nhánh hình dáng (S) được cộng trực tiếp vào kết quả cuối cùng để đảm bảo thông tin chi tiết không bị "pha loãng" qua quá trình xử lý thời gian.

$$x_{t+1} = x_t + S(x_t) + T(S(x_t)) \quad (3.9)$$

Trong khóa luận này, chúng tôi lựa chọn phiên bản **P3D-A** (như Hình 3.2). Lý do là vì trong bài toán nhận dạng dáng đi, sự thay đổi hình dáng là cơ sở để xác định chuyển động. Việc xử lý tuần tự Không gian $\rightarrow$ Thời gian giúp mô hình trích xuất các đặc trưng tĩnh ổn định trước khi phân tích sự biến đổi của chúng, phù hợp với kiến trúc phân cấp của HSTL.



Hình 3.2: Các biến thể của khối P3D: (a) P3D-A, (b) P3D-B, (c) P3D-C.

2. Độ phức tạp tính toán

Phân tích độ phức tạp thuật toán và tài nguyên tính toán:

Mô-đun ARME gốc trong HSTL sử dụng tích chập 3D tiêu chuẩn. Giả sử đầu vào có kích thước $C_{in} \times T \times H \times W$ và bộ lọc có kích

thước $k \times k \times k$. Chi phí tính toán (FLOPs) cho một thao tác là:

$$\text{FLOPs}_{S3D} \approx H \cdot W \cdot T \cdot C_{in} \cdot C_{out} \cdot k^3$$

Với P3D, ta phân rã thành $1 \times k \times k$ (Không gian) và $k \times 1 \times 1$ (Thời gian). Chi phí là:

$$\text{FLOPs}_{P3D} \approx H \cdot W \cdot T \cdot C_{in} \cdot C_{out} \cdot (k^2 + k)$$

Tỷ lệ giảm thiểu chi phí tính toán lý thuyết (R_{comp}) với $k = 3$:

$$R_{comp} = \frac{k^3}{k^2 + k} = \frac{27}{9 + 3} = \frac{27}{12} = 2.25$$

Về số lượng tham số, sự khác biệt cũng tương tự:

$$\text{Params}_{S3D} = C_{in} \cdot C_{out} \cdot k^3 = 27 \cdot C_{in} \cdot C_{out}$$

$$\text{Params}_{P3D} = C_{in} \cdot C_{out} \cdot (k^2 + k) = 12 \cdot C_{in} \cdot C_{out}$$

→ Giảm khoảng **55.6%** số lượng tham số tại các lớp tích chập. Điều này không chỉ giúp mô hình nhẹ hơn mà còn giảm thiểu đáng kể nguy cơ quá khớp trên các tập dữ liệu nhỏ, vì mô hình ít bậc tự do hơn buộc phải học các đặc trưng thiết yếu nhất.

Lý do chọn cấu trúc P3D-A: Trong ba biến thể (A, B, C) đã trình bày ở trên, chúng tôi chọn P3D-A vì tính phù hợp với bản chất dữ liệu đáng đi:

- Đáng đi được định nghĩa là sự thay đổi hình dáng theo thời gian.
- Cấu trúc P3D-A (Không gian → Thời gian) mô phỏng chính xác quá trình nhận thức này: trước tiên trích xuất đặc trưng hình dáng (không gian) tại mỗi thời điểm t , sau đó mô hình hóa

sự tiến hóa (thời gian) của các đặc trưng đó.

- Các thực nghiệm trong bài báo gốc [18] cũng chỉ ra P3D-A thường cho kết quả ổn định nhất trên các tác vụ video hành động.

3. Nhận định về quá trình huấn luyện

Mặc dù P3D tách biệt các thành phần không gian và thời gian, việc tích hợp các kết nối tắt trong khối P3D giúp quá trình lan truyền ngược đạo hàm diễn ra hiệu quả hơn so với mạng tích chập 3D thuần túy. Nhờ đó, mô hình đạt được khả năng hội tụ ổn định hơn, ngay cả khi độ sâu của mạng được gia tăng.

Nhờ số lượng tham số được giảm đáng kể, mô hình đề xuất tiêu thụ ít bộ nhớ đồ họa hơn trong quá trình lan truyền ngược. Điều này cho phép sử dụng kích thước lô huấn luyện lớn hơn trên cùng một cấu hình phần cứng. Trong các bài toán học đo lường, chẳng hạn như nhận dạng dáng đi, việc sử dụng kích thước lô lớn đóng vai trò then chốt, giúp mô hình học được các mẫu khó hiệu quả hơn, từ đó gián tiếp cải thiện độ chính xác.

3.1.3 Mô-đun gộp không gian-thời gian có khả năng thích ứng - ASTP

ASTP thực hiện ánh xạ đặc trưng phân cấp bằng cách áp dụng kỹ thuật gộp (**pooling**) không đều lên các vùng thu được từ $\mathcal{P}$. Với vùng j của mức l , $X_j^{(l)}$, mô-đun **ASTP** tại mức l , $\Gamma^{(l)}$, được biểu diễn như sau:

$$Y_{\Gamma,j}^{(l)} = \Gamma_j^{(l)}(X_j^{(l)}) = \text{GeM}_j \circ \text{FC} \circ \text{Max}(X_j^{(l)}), \quad (3.10)$$

trong đó, $\text{Max}(\cdot)$ là phép gộp dựa trên giá trị lớn nhất (max pooling) dọc theo trục thời gian, $\text{FC}(\cdot)$ là lớp kết nối đầy đủ, $\text{GeM}_j(\cdot)$ là phép gộp trung bình tổng quát (generalized mean pooling - GeM) [19] cho vùng j .

Chuỗi phép ánh xạ của Γ_j như sau: $\Gamma_j : \mathbb{R}^{C \times T \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C \times 1 \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C^{(l)} \times 1 \times H_j^{(l)} \times W} \mapsto \mathbb{R}^{C^{(l)} \times 1 \times 1 \times 1}$. Nối các $Y_{\Gamma,j}^{(l)}$ theo thứ tự, thu được $Y_{\Gamma}^{(l)} = [Y_{\Gamma,1}^{(l)}, Y_{\Gamma,2}^{(l)}, \dots, Y_{\Gamma,K_l}^{(l)}]$, với $Y_{\Gamma}^{(l)} \in \mathbb{R}^{C^{(l)} \times 1 \times K_l \times 1}$ là đầu ra của **ASTP** ở mức l .

3.1.4 Mô-đun tổng hợp đặc trưng theo thời gian ở mức khung hình - FTA

FTA nén các khung hình cục bộ để loại bỏ khung dư thừa bằng cách kết hợp đa tỉ lệ thời gian và chọn khung tại mức khung hình. Với vùng $X_j^{(l)}$, hai phép gộp theo thời gian với nhân $3 \times 1 \times 1$ và $5 \times 1 \times 1$ (với cùng độ trượt $3 \times 1 \times 1$) sinh ra $U_{j,1}^{(l)}$ và $U_{j,2}^{(l)}$, biểu diễn như sau:

$$\begin{aligned} \hat{U}_j^{(l)} &= U_{j,1}^{(l)} + U_{j,2}^{(l)} \\ &= \text{Max}_{3 \times 1 \times 1}^{3 \times 1 \times 1} (X_j^{(l)}) + \text{Max}_{5 \times 1 \times 1}^{3 \times 1 \times 1} (X_j^{(l)}), \end{aligned} \quad (3.11)$$

trong đó, $\text{Max}_{3 \times 1 \times 1}^{3 \times 1 \times 1}(\cdot)$ và $\text{Max}_{5 \times 1 \times 1}^{3 \times 1 \times 1}(\cdot)$ là phép gộp dựa trên giá trị lớn nhất. $\hat{U}_j^{(l)}$, $U_{j,1}^{(l)}$ và $U_{j,2}^{(l)}$ có cùng kích thước $(C, \frac{T}{3}, H_j^{(l)}, W)$.


Tiếp đó, **FTA** sinh trọng số lựa trong khung:

$$\begin{aligned} Z_{j,1}^{(l)} &= \text{FC}_{j,1}^{(l)} \left(\text{GAP} \left(\hat{U}_j^{(l)} \right) \right), \\ Z_{j,2}^{(l)} &= \text{FC}_{j,2}^{(l)} \left(\text{GAP} \left(\hat{U}_j^{(l)} \right) \right), \end{aligned} \quad (3.12)$$

trong đó, $\text{GAP}(\cdot)$ là phép gộp trung bình toàn cục dọc theo chiều không gian, $Z_{j,1}^{(l)}$ và $Z_{j,2}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times 1 \times 1}$. Trọng số được chuẩn hóa chéo trên 2 tỉ lệ, được biểu diễn như sau:

$$\mathcal{W}_{j,s,c,t}^{(l)} = \frac{e^{Z_{j,s,c,t}^{(l)}}}{e^{Z_{j,1,c,t}^{(l)}} + e^{Z_{j,2,c,t}^{(l)}}} \quad s \in \{1, 2\}, \quad (3.13)$$

trong đó, $\mathcal{W}_{j,s,c,t}^{(l)} \in \mathbb{R}^{1 \times 1 \times 1 \times 1}$ là trọng số của kênh c của khung hình t . Kết hợp biểu thức (3.11) và biểu thức (3.13), đầu ra vùng j , $Y_{\Omega,j}^{(l)} \in$



Hình 3.3: Minh họa mô-đun **FTA**.

$\mathbb{R}^{C^{(l)} \times \frac{T}{3} \times H_j^{(l)} \times W}$ ở mức l **FTA** được biểu diễn như sau:

$$Y_{\Omega,j}^{(l)} = \mathcal{W}_{j,1}^{(l)} \odot U_{j,1}^{(l)} + \mathcal{W}_{j,2}^{(l)} \odot U_{j,2}^{(l)}, \quad (3.14)$$


trong đó $\mathcal{W}_{j,1}^{(l)}, \mathcal{W}_{j,2}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times 1 \times 1}$ là 2 tensor trọng số được tính theo biểu thức (3.11), và $\odot$ là phép nhân trên từng phần tử. Kết quả của **FTA**, $Y_{\Omega}^{(l)} \in \mathbb{R}^{C \times \frac{T}{3} \times H \times W}$ được tạo bằng cách ghép nối K_l vùng của mức l , với $Y_{\Omega}^{(l)} = [Y_{\Omega,1}^{(l)}, Y_{\Omega,2}^{(l)}, \dots, Y_{\Omega,K_l}^{(l)}]$.

3.1.5 Hàm mất mát

Mô hình [4] gốc sử dụng đồng thời hàm mất mát bộ ba $\mathcal{L}_{triplet}$ [20] và hàm mất mát entropy chéo $\mathcal{L}_{ce}$, là bộ hàm mất mát phổ biến được dùng trong hầu hết nghiên cứu về nhận dạng dáng đi. Việc sử dụng kết hợp hai hàm này, dựa trên các nghiên cứu trong nhận diện khuôn mặt, tái định danh người, hay truy vấn ảnh, Điểm chung chính là bài toán nhận diện

dựa trên sự tương đồng và phân loại. Cụ thể hơn, hàm mất mát bộ ba, hay nhóm các hàm mất mát trong bài toán học nhãn theo cặp, bằng tối thiểu hóa khoảng cách giữa điểm neo với mẫu dương (cùng danh tính, hay cùng lớp), đồng thời tối đại hóa khoảng cách giữa điểm neo với mẫu âm (không cùng danh tính, hay khác lớp), trong không gian đặc trưng, cụ thể là không gian Euclidian. Hàm mất mát entropy chéo đóng vai trò hỗ trợ phân loại, hoạt động song song với hàm mất mát bộ ba. Nó giúp ổn định quá trình huấn luyện bằng cách buộc mô hình học các đặc trưng có khả năng phân biệt danh tính cụ thể trong tập huấn luyện, thay vì chỉ tối ưu khoảng cách tương đối.

Hàm mất mát bộ ba (Triplet Loss)



Hình 3.4: Phân tích độ lớn Gradient của Circle Loss (c) so với Triplet Loss (b).

Circle Loss tạo ra gradient mạnh hơn cho các mẫu khó (điểm A, hay vùng khoanh đỏ) [21].

Hàm mất mát bộ ba được thiết kế để học các embedding phân biệt bằng cách đảm bảo rằng khoảng cách giữa mẫu anchor và mẫu positive (cùng danh tính) nhỏ hơn khoảng cách giữa mẫu anchor và mẫu negative (khác danh tính) với một biên độ nhất định. Hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{triplet} = \frac{1}{N_{valid}} \sum_{i=1}^{N_{triplet}} \max(0, d(f(x_i^a), f(a_i^p)) - d(f(x_i^a), f(x_i^n)) + m) \quad (3.15)$$

trong đó:

- f_a^i, f_p^i, f_n^i lần lượt là các embedding của mẫu anchor, positive và negative trong bộ ba thứ i
- $d(\cdot, \cdot)$ là hàm khoảng cách Euclidean được tính theo công thức:

$$d(x, y) = \|f(x) - f(y)\|_2^2 \quad (3.16)$$

- m là tham số biên độ (margin) để tách biệt các mẫu cùng lớp và khác lớp
- $N_{triplet}$ là tổng số bộ ba được tạo ra từ batch
- N_{valid} là số lượng bộ ba có vi phạm ($\text{loss} > 0$), tức là các hard triplets

Việc chỉ tính trung bình trên các bộ ba có vi phạm giúp mô hình tập trung học từ các mẫu khó, từ đó cải thiện khả năng phân biệt.

Hàm mất mát Entropy chéo (Cross-Entropy Loss)

Hàm mất mát entropy chéo được sử dụng để phân loại các vec-tơ nhúng vào các lớp danh tính tương ứng. Mô hình áp dụng kỹ thuật *điều chỉnh tỉ lệ tạm thời* và *ràng buộc mềm trên nhãn* để cải thiện khả năng tổng quát hóa:

$$\mathcal{L}_{ce} = -\frac{1}{V \cdot N} \sum_{v=1}^V \sum_{j=1}^N \left[(1 - \epsilon) \sum_{k=1}^C y_{jk} \log p_{vjk} + \epsilon \cdot H(p_{vj}) \right] \quad (3.17)$$

trong đó:

- N là kích thước batch
- V là số lượng góc nhìn (theo không gian-thời gian) được trích xuất từ mỗi mẫu

- C là số lượng lớp danh tính
- y_{jk} là one-hot label của mẫu thứ j cho lớp k
- p_{vjk} là xác suất dự đoán được tính từ softmax với kĩ thuật điều chỉnh tỉ lệ tạm thời:

$$p_{vjk} = \frac{\exp(s \cdot z_{vjk})}{\sum_{k'=1}^C \exp(s \cdot z_{vjk'})} \quad (3.18)$$

với z_{vjk} là logit đầu ra và s là hệ số điều chỉnh tỉ lệ tạm thời.

- ϵ là hệ số ràng buộc mềm trên nhãn
- $H(p_{vj}) = -\frac{1}{C} \sum_{k=1}^C \log p_{vjk}$ là entropy của phân phối dự đoán, khuyến khích phân phối đồng đều hơn

Label smoothing với hệ số ϵ giúp tránh overfitting bằng cách ngăn mô hình quá tự tin vào các dự đoán, trong khi temperature scaling với hệ số s điều chỉnh độ mượt của phân phối xác suất đầu ra.

Hàm mất mát tổng hợp

Hàm mất mát tổng thể là tổng có trọng số của hai hàm mất mát trên:

$$\mathcal{L}_{total} = \lambda_{triplet} \mathcal{L}_{triplet} + \lambda_{ce} \mathcal{L}_{ce} \quad (3.19)$$

trong đó $\lambda_{triplet}$ và λ_{ce} lần lượt là trọng số của hàm mất mát bộ ba và hàm mất mát entropy chéo. Sự kết hợp này cho phép mô hình vừa học được các nhúng phân biệt thông qua học đặc trưng sâu ($\mathcal{L}_{triplet}$), vừa được hướng dẫn bởi thông tin phân lớp rõ ràng ($\mathcal{L}_{ce}$), tạo ra một không gian đặc trưng mạnh mẽ cho bài toán nhận dạng dáng đi.

Hạn chế của hàm mất mát bộ ba

Mặc dù được sử dụng rộng rãi trong các bài toán học đo lường, hàm mất mát bộ ba tồn tại một số hạn chế quan trọng:

1. **Tối ưu hóa cứng nhắc:** Triplet Loss áp dụng cùng một cường độ phạt (gradient có độ lớn bằng 1 hoặc -1) cho mọi bộ ba vi phạm margin, bất kể mức độ vi phạm. Một mẫu rất khó (hard sample với $d(a, p) \approx d(a, n)$) và một mẫu gần đạt biên độ (marginal sample) đều nhận được mức độ quan tâm như nhau từ hàm gradient, gây lãng phí tài nguyên tính toán.
2. **Mục tiêu hội tụ mơ hồ:** Hàm này chỉ quan tâm đến khoảng cách tương đối $d(a, n) - d(a, p) > \alpha$, dẫn đến việc mô hình có thể dừng tối ưu khi đạt điều kiện margin mà không đảm bảo $d(a, p)$ đủ nhỏ (mẫu cùng lớp chưa đủ gần) hoặc $d(a, n)$ đủ lớn (mẫu khác lớp chưa đủ xa). Điều này tạo ra nhiều cấu hình thỏa mãn điều kiện nhưng chất lượng embedding khác nhau.
3. **Phụ thuộc vào mẫu âm phức tạp:** Hiệu quả của Triplet Loss phụ thuộc rất lớn vào chiến lược chọn bộ ba. Quá trình này tốn kém tính toán (phải tính khoảng cách cho tất cả các cặp trong batch) và dễ gây mất ổn định trong quá trình huấn luyện nếu chọn mẫu quá khó.

Hàm mất mát Circle (Circle Loss)

Để khắc phục các hạn chế của hàm mất mát bộ ba, đặc biệt là sự thiếu linh hoạt trong tối ưu hóa và mục tiêu hội tụ không rõ ràng, chúng tôi đề xuất khảo sát việc sử dụng Circle Loss [21]. Hàm mất mát này được thiết kế với cơ chế tự động điều chỉnh cường độ phạt dựa trên mức độ tối ưu của từng cặp tương đồng (similarity pair).

Công thức toán học thống nhất:

Dựa trên quan điểm tối ưu hóa thống nhất cho cả học theo cặp và học theo lớp, Circle Loss tổng quát hóa việc tối thiểu hóa sự khác biệt ($s_n - s_p$) thành $(\alpha_n s_n - \alpha_p s_p)$. Công thức đầy đủ với các biên độ (margins) riêng biệt cho lớp trong và lớp ngoài được định nghĩa như sau [21]:

$$\mathcal{L}_{circle} = \log \left[1 + \sum_{j=1}^L \exp(\gamma \alpha_n^j (s_n^j - \Delta_n)) \cdot \sum_{i=1}^K \exp(-\gamma \alpha_p^i (s_p^i - \Delta_p)) \right] \quad (3.20)$$

trong đó:

- s_p^i là độ tương đồng cosine của cặp dương thứ i trong tập K mẫu cùng lớp.
- s_n^j là độ tương đồng cosine của cặp âm thứ j trong tập L mẫu khác lớp.
- Δ_p và Δ_n là biên độ nội lớp và biên độ ngoại lớp.
- γ là hệ số quy mô tinh chỉnh.
- α_p^i và α_n^j là các trọng số tự điều chỉnh, được xác định bởi:

$$\begin{cases} \alpha_p^i = [O_p - s_p^i]_+, \\ \alpha_n^j = [s_n^j - O_n]_+, \end{cases} \quad (3.21)$$

với $[\cdot]_+$ là toán tử "chỉ lấy giá trị dương", và O_p, O_n là các giá trị tối ưu mục tiêu ($O_p = 1 + m, O_n = -m$).

Cơ chế hoạt động:

Khác với Triplet Loss áp dụng cường độ phạt đồng đều, Circle Loss gán trọng số $\alpha_{p,i}$ và $\alpha_{n,j}$ một cách động. Cụ thể:

- Các cặp dương/tích cực có $s_{p,i}$ thấp (xa giá trị tối ưu O_p) sẽ có $\alpha_{p,i}$ lớn, dẫn đến gradient mạnh hơn, thúc đẩy mô hình ưu tiên tối ưu hóa các mẫu khó này.
- Ngược lại, các cặp âm/tiêu cực có $s_{n,j}$ cao (gần với positive, nguy hiểm) sẽ có $\alpha_{n,j}$ lớn, tạo áp lực mạnh để đẩy chúng xa hơn.

- Các cặp đã gần đạt tối ưu sẽ tự động nhận trọng số nhỏ, tránh lãng phí tài nguyên tính toán.

Điều này tạo ra một quá trình học *tự điều chỉnh*, trong đó mô hình tự động tập trung vào các mẫu quan trọng mà không cần chiến lược học trên mẫu khó, phức tạp như trong Triplet Loss. Hơn nữa, Circle Loss hướng đến mục tiêu hội tụ xác định: $s_p \rightarrow 1$ và $s_n \rightarrow 0$, thay vì chỉ quan tâm đến chênh lệch tương đối, giúp tạo ra không gian nhúng với ranh giới quyết định rõ ràng hơn.

So sánh Triplet Loss và Circle Loss

Bảng 3.1 trình bày so sánh chi tiết giữa hai hàm mất mát:

Bảng 3.1: So sánh Triplet Loss và Circle Loss

Khía cạnh	Triplet Loss	Circle Loss
Đơn vị đo	Khoảng cách Euclidean	Độ tương đồng Cosine
Cường độ phạt	Đồng đều cho mọi vi phạm	Trọng số động theo mức độ vi phạm
Mục tiêu hội tụ	Tương đối: $d(a, n) - d(a, p) > \alpha$	Tuyệt đối: $s_p \rightarrow 1, s_n \rightarrow 0$
Hard mining	Yêu cầu chiến lược mining	Tự động qua self-paced weighting
Gradient	Hằng số cho mỗi vi phạm	Thích ứng theo trọng số tự điều chỉnh
Ranh giới quyết định	Tuyến tính	Hình tròn

Kỳ vọng với bài toán nhận dạng dáng đi:

Trong ngữ cảnh nhận dạng dáng đi với biến thể lớn về góc nhìn, trang phục và điều kiện di chuyển, Circle Loss hứa hẹn mang lại những lợi thế sau:

1. **Xử lý tốt hơn biến thể nội lớp:** Cơ chế tự điều chỉnh giúp mô hình tự động làm nổi bật các trường hợp khó (ví dụ: cùng người nhưng

góc nhìn 90° so với 0° , hoặc mặc áo khoác dày), từ đó học được các đặc trưng bất biến vững chắc hơn.

2. **Không gian embedding rõ ràng hơn:** Mục tiêu hội tụ xác định ($s_p \rightarrow 1, s_n \rightarrow 0$) thay vì chỉ quan tâm đến chênh lệch tương đối, giúp tạo ra ranh giới quyết định rõ ràng giữa các lớp, đặc biệt quan trọng trong kiến trúc phân cấp của HSTL.
3. **Ổn định và hiệu quả hơn trong training:** Không phụ thuộc vào chiến lược hard triplet mining phức tạp, Circle Loss đơn giản hóa quá trình huấn luyện và giảm thiểu nguy cơ training collapse, đồng thời kỳ vọng đạt được tốc độ hội tụ nhanh hơn.

Cơ chế Tự điều chỉnh và Đạo hàm

Để hiểu tại sao Circle Loss vượt trội, hãy tưởng tượng việc huấn luyện như quá trình dạy học.

Hàm Triplet Loss giống như một giáo viên máy móc: dù học sinh làm bài sai ít hay sai nhiều (miễn là chưa đạt điểm tối đa), giáo viên đều phạt một mức như nhau (Gradient = hằng số).

$$\frac{\partial \mathcal{L}_{triplet}}{\partial s_p} = -1 \quad (\text{nếu có vi phạm}) \quad (3.22)$$

Cách này không hiệu quả: nó lãng phí sức lực vào những bài đã gần đúng, trong khi chưa đủ nghiêm khắc với những bài sai trầm trọng.

Ngược lại, Circle Loss hoạt động như một giáo viên thông minh biết "nhìn người mà dạy". Circle Loss tự động điều chỉnh "hình phạt" dựa trên năng lực hiện tại của từng mẫu dữ liệu:

1. **Với mẫu khó :** Nếu mẫu positive (s_p) đang bị nhận diện kém (còn xa đích tối ưu $O_p = 1 + m$), hệ số tự điều chỉnh $\alpha_p = [O_p - s_p]_+$ sẽ rất lớn. Gradient lúc này sẽ cực mạnh, buộc mô hình phải sửa sai ngay lập tức.

2. **Với mẫu dễ** : Nếu mẫu đã đạt chuẩn (tiến gần O_p), α_p tự động giảm về 0. Gradient nhỏ đi, mô hình chỉ tinh chỉnh nhẹ nhàng để tránh làm hỏng các đặc trưng đã học tốt.

Về mặt toán học, điều này thể hiện qua đạo hàm của Circle Loss tỉ lệ thuận với khoảng cách đến đích tối ưu:

$$\frac{\partial \mathcal{L}_{circle}}{\partial s_p} \propto (s_p - O_p) = (s_p - (1 + m)) \quad (3.23)$$

Chính cơ chế "mềm nắn rắn buông" này giúp Circle Loss hội tụ nhanh hơn và đạt được kết quả chính xác hơn, tạo ra một không gian đặc trưng nơi các mẫu cùng lớp tụ lại chặt chẽ và các lớp khác nhau được đẩy xa nhau một cách rõ ràng.

Hàm mất mát tổng hợp với Circle Loss

Tương tự như cấu hình gốc, hàm mất mát tổng thể trong nghiên cứu này kết hợp Circle Loss với Cross-Entropy Loss:

$$\mathcal{L}_{total} = \lambda_{circle} \mathcal{L}_{circle} + \lambda_{ce} \mathcal{L}_{ce} \quad (3.24)$$

trong đó λ_{circle} và λ_{ce} lần lượt là trọng số của hàm mất mát Circle và hàm mất mát entropy chéo. Sự kết hợp này cho phép mô hình vừa học được các embedding phân biệt với khả năng tự điều chỉnh thông qua metric learning ($\mathcal{L}_{circle}$), vừa được hướng dẫn bởi thông tin phân lớp rõ ràng ($\mathcal{L}_{ce}$), tạo ra một không gian đặc trưng mạnh mẽ và tối ưu hơn cho bài toán nhận dạng dáng đi.

Chương 4

Thực nghiệm và Kết quả

4.1 Cài đặt thực nghiệm

4.1.1 Bộ dữ liệu CASIA-B

CASIA-B [22] là bộ dữ liệu chuẩn phổ biến nhất cho nhận dạng dáng đi. Bộ dữ liệu bao gồm 124 chủ thể, mỗi chủ thể có 11 góc nhìn khác nhau (từ 0° đến 180° , bước nhảy 18°). Mỗi chủ thể di chuyển trong 3 điều kiện:

- **NM:** Đi bộ bình thường (6 đoạn video/chủ thể).
- **BG:** Đi bộ có mang túi xách (2 đoạn video/chủ thể).
- **CL:** Đi bộ mặc áo khoác dày (2 đoạn video/chủ thể).

Giao thức đánh giá: Chúng tôi tuân theo giao thức chuẩn được sử dụng rộng rãi trong các nghiên cứu trước [7], [16]:

- **Training set:** 74 chủ thể đầu tiên.
- **Test set:** 50 chủ thể còn lại.
- Trong quá trình kiểm tra (Testing), 4 đoạn video NM đầu tiên (NM#01-04) được dùng làm **Gallery** (tập mẫu), và các đoạn còn lại (NM#05-06, BG#01-02, CL#01-02) được dùng làm **Probe** (tập cần nhận dạng).

4.1.2 Chi tiết cài đặt

Mô hình được cài đặt trên nền tảng PyTorch. Các tham số cấu hình chính như sau:

- **Input:** Ảnh silhouettes đầu vào được cắt (crop) và căn chỉnh về kích thước 64×44 .
- **Batch Size:** ($P = 8, K = 8$), tức là mỗi batch chọn 8 chủ thể, mỗi chủ thể lấy 8 đoạn video ngẫu nhiên.
- **Training Frames:** Trong quá trình huấn luyện, chúng tôi lấy mẫu cố định 30 frame ($T = 30$) từ mỗi đoạn video. Trong quá trình kiểm tra, toàn bộ frame được sử dụng.
- **Loss Function:**
 - **Circle Loss:** Margin $m = 0.25$, Scale factor $\gamma = 128$.
 - **Cross Entropy Loss:** Sử dụng Label Smoothing với hệ số 0.1.
- **Optimizer:** Adam với learning rate ban đầu $1e - 4$, weight decay $5e - 4$. Learning rate được giảm đi 0.1 sau mỗi 70K iterations. Tổng số vòng lặp là 100K.

4.1.3 Chi tiết Kiến trúc Mô hình

Bảng 4.1 mô tả chi tiết các tham số kiến trúc của HSTL trên tập dữ liệu CASIA-B. Mô hình bao gồm 4 mức phân cấp (Level 1-4).

- **Level 1:** Xử lý toàn bộ cơ thể ($K_1 = 1$) như một khối thống nhất.
- **Level 2:** Phân chia cơ thể thành 2 phần (thân trên và thân dưới) ($\{\{1..5\}, \{6..8\}\}$), kết hợp với module FTA để giảm chiều thời gian.
- **Level 3:** Phân chia chi tiết hơn thành 4 phần ($\{\{1\}, \{2..5\}, \{6, 7\}, \{8\}\}$).

- **Level 4:** Phân chia mịn nhất thành 8 phần riêng biệt (mỗi phần tương ứng một dải đặc trưng).

Bảng 4.1: Kiến trúc chi tiết của mô hình HSTL đề xuất (biến thể P3D) trên CASIA-B. Các khối Conv3d ở Level 2 và 3 được thay thế bằng P3D-A (S + T).

Mức	Mô-đun	Lớp	C_{in}	C_{out}	Nhân	K_l	Tập phân nhóm
1	ARME	Conv3d	1	32	(3,3,3)	1	$\{\{1..8\}\}$
	ASTP						
2	ARME	P3D-A (S)	32	32	(1,3,3)	2	$\{\{1..5\}, \{6..8\}\}$
		P3D-A (T)	32	32	(3,1,1)		
		P3D-A (S)	32	64	(1,3,3)		
		P3D-A (S)	64	64	(3,1,1)		
	ASTP						
	FTA	MaxPool	64	64	(3,1,1)		
3	ARME	P3D-A (S)	64	128	(1,3,3)	4	$\{\{1\}, \{2..5\}, \{6, 7\}, \{8\}\}$
		P3D-A (T)	128	128	(3,1,1)		
		P3D-A (S)	128	128	(1,3,3)		
		P3D-A (T)	128	128	(3,1,1)		
	ASTP						
	ASTP						
4	ASTP					8	$\{\{1\}..\{8\}\}$

4.2 So sánh với các phương pháp SOTA

Bảng 4.2 trình bày kết quả so sánh độ chính xác Rank-1 trên bộ dữ liệu CASIA-B giữa phương pháp đề xuất (HSTL) và các phương pháp tiên tiến khác (GaitSet, GaitPart, GaitGL, 3D Local, v.v.).

4.3 Phân tích Thực nghiệm

4.3.1 Khảo sát và Phân tích Cấu trúc P3D

Trong chương 3, chúng tôi đã đề xuất sử dụng P3D thay vì Conv3D tiêu chuẩn để giảm tải tính toán. Dựa vào các phân tích lý thuyết và thực

Bảng 4.2: Độ chính xác Rank-1 (%) trên CASIA-B trong các điều kiện khác nhau (NM, BG, CL).

Gallery NM #1-4		0° – 180°											Mean	Std
Probe		0°	18°	36°	54°	72°	90°	108°	126°	144°	162°	180°		
NM #5-6	GaitSet [16]	90.8	97.9	99.4	96.9	93.6	91.7	95.0	97.8	98.9	96.8	85.8	95.0	3.5
	GaitPart [7]	94.1	98.6	99.3	98.5	94.0	92.3	95.9	98.4	99.2	97.8	90.4	96.2	3.1
	3D Local [23]	96.0	<u>99.0</u>	<u>99.5</u>	<u>98.9</u>	97.1	94.2	96.3	99.0	98.8	98.5	95.2	97.5	1.8
	CSTL [24]	97.2	<u>99.0</u>	99.2	98.1	96.2	<u>95.5</u>	<u>97.7</u>	98.7	99.2	<u>98.9</u>	96.5	<u>97.8</u>	1.3
	GaitGL [8]	96.0	98.3	99.0	97.9	96.9	95.4	97.0	98.9	<u>99.3</u>	98.8	94.0	97.4	1.7
	LagrangeGait [25]	95.7	98.1	99.1	98.3	96.4	95.2	97.5	99.0	<u>99.3</u>	<u>98.9</u>	94.9	97.5	1.6
	MetaGait [26]	<u>97.3</u>	99.2	<u>99.5</u>	99.1	<u>97.2</u>	<u>95.5</u>	97.6	<u>99.1</u>	<u>99.3</u>	99.1	<u>96.7</u>	98.1	<u>1.3</u>
	HSTL (*)	97.6	98.0	99.6	98.2	97.4	96.5	97.9	99.3	99.4	98.4	97.0	98.1	1.0
	HSTL (Góc)	96.4	98.3	98.9	98.00	97.0	96.1	97.5	99.2	99.4	99.20	95.7	97.8	1.3
	HSTL (P3D)	95.8	98.2	99.1	98.20	96.3	95.5	97.8	99.0	99.0	98.80	94.5	97.5	1.6
BG #1-2	HSTL (Circle Loss)	96.0	98.9	99.1	98.40	95.7	93.5	96.5	98.8	98.5	98.40	91.1	96.8	2.5
	HSTL (P3D + Circle Loss)	94.2	98.3	98.9	97.90	94.6	93.4	96.6	98.9	98.4	99.10	91.0	96.5	2.6
	GaitSet [16]	83.8	91.2	91.8	88.8	83.3	81.0	84.1	90.0	92.2	94.4	79.0	87.2	4.9
	GaitPart [7]	89.1	94.8	96.7	95.1	88.3	84.9	89.0	93.5	96.1	93.8	85.8	91.5	4.2
	3D Local [23]	92.9	95.9	97.8	96.2	93.0	87.8	92.7	96.3	97.9	98.0	88.5	94.3	3.5
	CSTL [24]	91.7	96.5	97.0	95.4	90.9	88.0	91.5	95.8	97.0	95.5	90.3	93.6	3.0
	GaitGL [8]	92.6	<u>96.6</u>	96.8	95.5	93.5	89.3	92.2	96.5	98.2	96.9	91.5	94.5	2.8
	LagrangeGait [25]	<u>94.2</u>	96.2	<u>96.8</u>	95.8	94.3	89.5	91.7	96.8	98.0	97.0	90.9	94.6	2.7
	MetaGait [26]	92.9	96.7	97.1	<u>96.4</u>	<u>94.7</u>	<u>90.4</u>	<u>92.9</u>	97.2	<u>98.5</u>	98.1	<u>92.3</u>	<u>95.2</u>	2.6
	HSTL (*)	95.0	96.5	<u>97.3</u>	96.6	95.3	93.3	94.6	<u>96.8</u>	98.6	<u>97.7</u>	92.9	95.9	1.7
CL #1-2	HSTL (Góc)	94.0	96.6	97.1	96.26	95.1	91.4	93.9	97.5	98.4	97.78	93.0	95.5	2.1
	HSTL (P3D)	92.9	96.1	96.8	95.35	94.3	90.9	93.4	97.1	97.8	96.87	91.5	94.8	2.3
	HSTL (Circle Loss)	92.2	96.3	96.8	95.76	92.1	88.3	90.9	96.2	97.2	95.66	86.1	93.4	3.6
	HSTL (P3D + Circle Loss)	90.9	96.2	97.1	94.95	90.2	86.8	89.9	95.5	97.4	95.15	84.5	92.6	4.2
	GaitSet [16]	61.4	75.4	80.7	77.3	72.1	70.1	71.5	73.5	73.5	68.4	50.0	70.4	8.0
	GaitPart [7]	70.7	85.5	86.9	83.3	77.1	72.5	76.9	82.2	83.8	80.2	66.5	78.7	6.6
	3D Local [23]	78.2	90.2	92.0	87.1	83.0	76.8	83.1	86.6	86.8	84.1	70.9	83.7	6.2
	CSTL [24]	78.1	89.4	91.6	86.6	82.1	79.9	81.8	86.3	88.7	86.6	75.3	84.2	<u>4.9</u>
	GaitGL [8]	76.6	90.0	90.3	87.1	84.5	79.0	84.1	87.0	87.3	84.4	69.5	83.6	6.3
	LagrangeGait [25]	77.4	90.6	<u>93.2</u>	<u>90.2</u>	84.7	80.3	<u>85.2</u>	87.7	89.3	86.6	71.0	85.1	6.3
CL #1-2	MetaGait [26]	<u>80.0</u>	<u>91.8</u>	93.0	87.8	<u>86.5</u>	<u>82.9</u>	<u>85.2</u>	<u>90.0</u>	<u>90.8</u>	<u>89.3</u>	<u>78.4</u>	<u>86.9</u>	4.6
	HSTL (*)	82.4	94.2	95.0	91.7	88.2	83.3	88.0	92.3	93.1	91.0	78.5	88.9	5.1
	HSTL (Góc)	81.1	93.1	94.9	92.60	88.0	84.5	86.4	91.7	92.9	90.70	76.3	88.4	5.5
	HSTL (P3D)	77.4	90.5	91.4	89.90	86.7	81.8	84.1	87.7	89.5	86.50	72.3	85.3	5.7
	HSTL (Circle Loss)	69.4	90.6	94.6	89.30	82.7	77.6	80.9	88.1	89.3	86.40	65.0	83.1	8.8
	HSTL (P3D + Circle Loss)	67.5	89.4	91.5	86.30	79.4	74.6	79.3	83.7	86.8	83.10	61.9	80.3	8.8

Kết quả **HSTL**[4] được lấy từ bài báo công bố, ký hiệu (*).

th nghiệm sơ bộ, P3D mang lại ưu điểm vượt trội về hiệu suất tính toán:

Bảng 4.3: So sánh giữa Conv3D và P3D-A về số lượng tham số và chi phí tính toán.

Loại tích chập	Tham số	Chi phí (FLOPs)
Conv3D ($3 \times 3 \times 3$)	$\approx 27 \times C_{in} \times C_{out}$	Cao (100%)
P3D-A ($1 \times 3 \times 3 + 3 \times 1 \times 1$)	$\approx (9 + 3) \times C_{in} \times C_{out} = 12 \times \dots$	Thấp ($\approx 44\%$)

Việc sử dụng P3D không chỉ giúp mô hình nhẹ hơn (giảm $\sim 56\%$ tham số) mà còn duy trì được độ chính xác tương đương nhờ khả năng tách biệt việc học đặc trưng không gian và thời gian, giúp giảm thiểu hiện tượng overfitting trên các tập dữ liệu nhỏ như CASIA-B.

4.3.2 Khảo sát Hàm mất mát

Mục tiêu của phần này là đánh giá tác động của Circle Loss so với Triplet Loss truyền thống.


- **Triplet Loss:** Gặp khó khăn khi các mẫu đã phân tách nhưng chưa đủ biên độ an toàn, dẫn đến gradient biến mất hoặc dao động.
- **Circle Loss:** Với cơ chế *Self-paced Weighting*, hàm mất mát này duy trì gradient mạnh mẽ cho các mẫu khó và giảm nhẹ cho các mẫu dễ, giúp không gian đặc trưng phân tách rõ ràng hơn.

Tuy nhiên, bảng kết quả cho thấy biến thể của HSTL có kết hợp Circle Loss đều kém đi rất nhiều so với mô hình gốc. Lý do là vì, chúng tôi đã mắc sai lầm khi không phân biệt rõ vai trò của Circle Loss. Circle Loss được đề xuất, về mặt lý thuyết và kiểm chứng, rằng sẽ thay thế hoàn toàn sự kết hợp của Triplet Loss và Cross-Entropy Loss. Nhưng chúng tôi lại chỉ thay thế Triplet Loss bằng Circle Loss, giữ nguyên CE Loss, dẫn đến toàn bộ khảo sát đã sai, và kém đi. Tuy nhiên, nếu thực nghiệm đúng, có thể kết quả sẽ tốt hơn như mong đợi ở 3. Chúng ta có thể theo dõi các biểu đồ sau.


4.3.3 Phân tích Hội tụ và Độ ổn định

Chúng tôi theo dõi quá trình huấn luyện thông qua độ chính xác Rank-1 trên tập xác thực.

Cả 3 hình 4.1, 4.2, 4.3 cho thấy, biến thể P3D là một cải tiến tốt so với bản gốc, tuy nhiên các biến thể có sự tham gia của Circle Loss đều kém đi rất nhiều, mặc dù chúng vẫn đạt sự hiệu quả tương đối cao, chỉ kém đi khoảng 2% trên tổng thể.



Hình 4.1: Độ chính xác Rank-1 (NM) theo bước lặp.




Hình 4.2: Độ chính xác Rank-1 (BG) theo bước lặp.

4.3.4 Phân tích Chi tiết theo Góc nhìn


Để có cái nhìn sâu hơn về hiệu năng tại vòng lặp cuối cùng (100K), chúng tôi biểu diễn phân bố độ chính xác theo từng góc nhìn (0-180 độ) trong Hình 4.6.

Từ biểu đồ Scatter:

- **Góc 90° (Góc ngang):** Luôn là góc khó nhất (acc thấp nhất) do thông tin hình dáng bị hạn chế nhất (ít diện tích silhouette).




Hình 4.3: Độ chính xác Rank-1 (CL) theo bước lặp.




Hình 4.4: Phân bố độ chính xác theo góc nhìn (NM).

- **Góc $0^\circ/180^\circ$ (Trước/Sau):** Độ chính xác cao hơn nhưng vẫn thấp hơn các góc nghiêng ($36^\circ - 144^\circ$).
- **So sánh Mô hình:** P3D duy trì độ chính xác rất cạnh tranh so với Baseline ở hầu hết các góc nhìn, ngoại trừ một số sụt giảm nhỏ ở góc



Hình 4.5: Phân bố độ chính xác theo góc nhìn (BG).

90° trong điều kiện CL, điều này chấp nhận được để đổi lấy tốc độ thực thi.



Hình 4.6: Phân bố độ chính xác theo góc nhìn (CL) tại vòng lặp 100K. Các điểm màu xanh (Gốc) và cam (P3D) thường chồng lên nhau, trong khi Circle Loss (nếu có) thể hiện sự phân tán khác biệt ở các góc khó.

Chương 5

Kết luận và Hướng phát triển

5.1 Kết luận

Trong khóa luận này, chúng tôi đã tập trung khảo sát các hạn chế của mô hình nhận dạng dáng đi HSTL gốc, cụ thể là chi phí tính toán cao của khối tích chập 3D và sự thiếu linh hoạt của hàm mất mát Triplet Loss. Các kết luận chính được rút ra từ phân tích lý thuyết và thực nghiệm tại Chương 4 bao gồm:

1. **Tối ưu hóa kiến trúc với P3D:** Chúng tôi đã chứng minh rằng việc thay thế các khối tích chập 3D bằng P3D-A (tích chập 2D không gian kết hợp 1D thời gian) là một chiến lược hiệu quả. Phân tích thực nghiệm cho thấy P3D giúp giảm khoảng **50% số lượng tham số** và **2.25 lần chi phí tính toán (FLOPs)** so với Conv3D, trong khi vẫn duy trì độ chính xác nhận dạng tương đương. Cấu trúc P3D-A phù hợp tự nhiên với quá trình nhận thức dáng đi: nhận diện hình dáng trước, sau đó phân tích chuyển động.
2. **Nâng cao khả năng phân biệt với Circle Loss:** Về mặt lý thuyết, một điều chắc chắn rằng hàm Circle Loss có thể cải thiện HSTL. Tuy nhiên, chúng tôi đã mắc sai lầm lớn trong việc nghiên cứu và cài đặt thực nghiệm, dẫn đến kết quả kém. Do đó, khảo sát này không dám khẳng định giải thuyết mà chúng tôi đã đề ra trước đó.

5.2 Hạn chế

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn còn một số hạn chế:

- **Dữ liệu phân đoạn:** Mô hình vẫn phụ thuộc hoàn toàn vào chất lượng của ảnh hình bóng đầu vào. Nếu quá trình tách nền (segmentation) thất bại (mất chân, mất tay), hiệu suất nhận dạng sẽ giảm mạnh.
- **Tốc độ suy diễn thực tế:** Dù đã giảm FLOPs, nhưng việc suy diễn trên CPU vẫn còn chậm so với yêu cầu thời gian thực.
- **Sự bất cần trong quy trình nghiên cứu khoa học:** Chính điều này dẫn thiếu kết quả tẻ khi khảo sát Circle Loss.

5.3 Hướng phát triển

Dựa trên các xu hướng nghiên cứu mới nhất năm 2024-2025, chúng tôi đề xuất các hướng phát triển tiếp theo:

1. **Tái thực nghiệm với Circle Loss:** Đây là điều chắc chắn chúng tôi sẽ làm để hoàn thiện nghiên cứu này theo kế hoạch đề ra.
2. **Tích hợp Kiến trúc Không gian Trạng thái (Mamba):** Như đã thảo luận trong chương 2, mô hình **MambaGait** cho thấy khả năng xử lý chuỗi dài với chi phí tuyến tính. Việc thay thế bộ trích xuất thời gian bằng các khối Mamba có thể giúp mô hình nắm bắt thông tin đáng đi trong thời gian dài hơn hiệu quả hơn.
3. **Tăng cường dữ liệu với cấu trúc xương:** Tích hợp thêm thông tin khung xương 2D/3D (như **DAGait**) để hướng dẫn quá trình căn chỉnh ảnh hoặc bổ sung thông tin khi ảnh bóng đáng bị nhiễu.

4. **Triển khai trên thiết bị biên:** Thực hiện lượng tử hóa mô hình xuống dạng FP16 hoặc INT8 để triển khai trên các thiết bị nhúng như NVIDIA Jetson, tối ưu hóa cho ứng dụng giám sát thực tế.

Tài liệu tham khảo

Tiếng Anh

- [1] Sarkar, S. and Kale, A., “Gait recognition,” in *Handbook of Biometrics*, Jain, A. K., Flynn, P., and Ross, A. A., Eds., Springer US, 2008, pp. 109–130.
- [2] Sepas-Moghaddam, A. and Etemad, A., “Deep gait recognition: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.
- [3] Shen, C., Yu, S., Wang, J., Huang, G. Q., and Wang, L., *A comprehensive survey on deep gait recognition: Algorithms, datasets and challenges*, 2023. arXiv: 2206.13732 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2206.13732>
- [4] Wang, L., Liu, B., Liang, F., and Wang, B., *Hierarchical spatio-temporal representation learning for gait recognition*, 2023. arXiv: 2307.09856 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2307.09856>
- [5] Zheng, J., Liu, X., Liu, W., He, L., Yan, C., and Mei, T., *Gait recognition in the wild with dense 3d representations and a benchmark*, 2022. arXiv: 2204.02569 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2204.02569>
- [6] Shen, C., Fan, C., Wu, W., Wang, R., Huang, G. Q., and Yu, S., *Lidargait: Benchmarking 3d gait recognition with point clouds*, 2023.

- arXiv: 2211.10598 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2211.10598>
- [7] Fan, C. et al., “Gaitpart: Temporal part-based model for gait recognition,” in *CVPR*, 2020, pp. 14 225–14 233.
 - [8] Lin, B., Zhang, S., and Yu, X., “Gait recognition via effective global-local feature representation and local temporal aggregation,” in *ICCV*, 2021, pp. 14 648–14 656.
 - [9] Teepe, T., Khan, A., Gilg, J., Herzog, F., Hörmann, S., and Rigoll, G., “Gaitgraph: Graph convolutional network for 3d gait recognition,” in *2021 IEEE International Conference on Image Processing (ICIP)*, IEEE, 2021, pp. 959–963.
 - [10] Li, R., Liu, X., Cao, C., and Huang, Y., “End-to-end model-based gait recognition,” in *Proceedings of the Asian Conference on Computer Vision*, 2020.
 - [11] Shen, C., Lin, B., Zhang, S., Huang, G. Q., Yu, S., and Yu, X., *Gait recognition with mask-based regularization*, 2022. arXiv: 2203.04038 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2203.04038>
 - [12] Liang, J., Fan, C., Hou, S., Shen, C., Huang, Y., and Yu, S., *Gaitedge: Beyond plain end-to-end gait recognition for better practicality*, 2022. arXiv: 2203.03972 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2203.03972>
 - [13] Xiong, H., Feng, B., Wang, B., Wang, X., and Liu, W., “Mambagait: Gait recognition approach combining explicit representation and implicit state space model,” *Image and Vision Computing*, vol. 161, p. 105 597, 2025.
 - [14] Wu, Z., Zhang, C., Xu, H., Jiao, P., and Wang, H., “Dagait: Generalized skeleton-guided data alignment for gait recognition,” *arXiv preprint arXiv:2503.18830*, 2025.

- [15] Gupta, A. and Chellappa, R., “Mimicgait: A model agnostic approach for occluded gait recognition using correlational knowledge distillation,” *arXiv preprint arXiv:2501.15666*, 2025, Accepted to WACV 2025.
- [16] Chao, H., He, Y., Zhang, J., and Feng, J., “Gaitset: Regarding gait as a set for cross-view gait recognition,” in *AAAI*, 2019, pp. 8126–8133.
- [17] Deng, Y., Xiong, H., and Feng, B., “Licaf: Lidar-camera asymmetric fusion for gait recognition,” in *IEEE International Conference on Image Processing (ICIP)*, 2024.
- [18] Qiu, Z., Yao, T., and Mei, T., *Learning spatio-temporal representation with pseudo-3d residual networks*, 2017. arXiv: 1711.10305 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/1711.10305>
- [19] Radenović, F., Tolias, G., and Chum, O., “Fine-tuning cnn image retrieval with no human annotation,” *IEEE TPAMI*, vol. 41, no. 7, pp. 1655–1668, 2018.
- [20] Schroff, F., Kalenichenko, D., and Philbin, J., “Facenet: A unified embedding for face recognition and clustering,” in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, Jun. 2015, pp. 815–823. DOI: 10.1109/cvpr.2015.7298682 [Online]. Available: <http://dx.doi.org/10.1109/CVPR.2015.7298682>
- [21] Sun, Y. et al., *Circle loss: A unified perspective of pair similarity optimization*, 2020. arXiv: 2002.10857 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2002.10857>
- [22] Yu, S., Tan, D., and Tan, T., “A framework for evaluating the effect of view angle, clothing and carrying condition on gait recognition,” in *ICPR*, 2006, pp. 441–444.
- [23] Huang, Z. et al., “3d local convolutional neural networks for gait recognition,” in *ICCV*, 2021, pp. 14 920–14 929.

- [24] Huang, X. et al., “Context-sensitive temporal feature learning for gait recognition,” in *ICCV*, 2021, pp. 12 909–12 918.
- [25] Chai, T., Li, A., Zhang, S., Li, Z., and Wang, Y., “Lagrange motion analysis and view embeddings for improved gait recognition,” in *CVPR*, 2022, pp. 20 249–20 258.
- [26] Dou, H., Zhang, P., Su, W., Yu, Y., and Li, X., “Metagait: Learning to learn an omni sample adaptive representation for gait recognition,” in *ECCV*, Springer, 2022, pp. 357–374.

Chương 6

Danh mục thuật ngữ và chữ viết tắt

Thuật ngữ / Viết tắt	Giải nghĩa
Gait Recognition	Nhận dạng dáng đi
Human Mesh Recovery	Mạng khôi phục người trong dữ liệu lưới
State Space Model	Mô hình không gian trạng thái
Knowledge Distillation	Cơ Chế chưng cất tri thức
HSTL	Hierarchical Spatio-Temporal Representation Learning (Học biểu diễn không gian-thời gian phân cấp)
P3D	Pseudo-3D Convolution (Tích chập giả 3 chiều)
Conv3D	3D Convolution (Tích chập 3 chiều)
ARME	Adaptive Region-based Motion Extractor (Bộ trích xuất chuyển động dựa trên vùng thích ứng)
FTA	Frame-level Temporal Aggregation (Tổng hợp đặc trưng theo thời gian ở mức khung hình)
ASTP	Adaptive Spatio-Temporal Pooling (Gộp không gian-thời gian thích ứng)
Triplet Loss	Hàm mất mát bộ ba
Circle Loss	Hàm mất mát trong giới hạn biên hình tròn, (Hàm mất mát tròn)
self-paced weighting	Cơ chế trọng số tự điều chỉnh
GEI	Gait Energy Image (Ảnh năng lượng dáng đi)
SOTA	State-of-the-art (Tiên tiến nhất hiện nay)
FLOPs	Floating Point Operations (Số phép tính dấu phẩy động)
Rank-1 Accuracy	Độ chính xác xếp hạng 1 (Tỷ lệ mẫu đúng nhất nằm ở vị trí đầu tiên)
OUMVLP	Osaka University Multi-View Large Population Dataset
CASIA-B	Institute of Automation, Chinese Academy of Sciences (Dataset B)